Lista 2.

Amelia Olejniczak

Contents

1 Zadanie 1. **2**

2 Zadanie 2. **2**

3 Zadanie 3. **4**

4 Zadanie 4. **5**

5 Zadanie 5. **6**

6 Zadanie 6. **7**

7 Zadanie 7. **9**

8 Zadanie 8. **9**

8.1 Moc testu 9

8.2 Wykres 10

9 Zadanie 9. **12**

9.1 $\beta_1 = 0, \epsilon \sim N(0, I)$ 12

9.2 $\beta_1 = 0, \epsilon_1, ..., \epsilon_{200}$ iid z rozkładu wykładniczego $Exp(1)$ 13

9.3 $\beta_1 = 0, \epsilon_1, ..., \epsilon_{200}$ iid z rozkładu logistycznego $L(0, 1)$ 14

9.4 $\beta_1 = 2, \epsilon \sim N(0, 1)$ 14

9.5 $\beta_1 = 2, \epsilon_1, ..., \epsilon_{200}$ iid z rozkładu wykładniczego $Exp(1)$ 15

9.6 $\beta_1 = 0, \epsilon_1, ..., \epsilon_{200}$ iid z rozkładu logistycznego $L(0, 1)$ 15

10 Zadanie teoretyczne **16**

10.1 95% przedział ufności dla β_1 16

10.2 Czy istnieje statystyczne uzasadnienie dla twierdzenia, że Y zależy od X? 16

10.3 Przedział predykcyjny dla E(Y), gdy znany jest przedział ufności 16

1 Zadanie 1.

Do wykonania tego i kolejnych zadań wykorzystam dane o zależności czasu utrzymania od liczby kopiarek zapisane w pliku **CH01PR20.txt**. W pierwszym zadaniu mam przedstawić wszystkie dane na wykresie, zatem w poniższym kodzie to właśnie robię.

Jak można zobaczyć, zapisuję dane z wyżej podanego pliku tekstowego do tabeli danych, którą nazywam `data`. Następnie zmieniam nazwy kolumn tak, by odzwierciedlały to, co znajduje się w pliku.

Do narysowania wykresu punktowego wykorzystuję funkcję `plot`. Zmieniam w nim nazwy osi, kolor punktów oraz ich kształt.

```
data <- read.table('CH01PR20.txt')
colnames(data) <- c("Czas", "Liczba_kopiarek")
plot(data$Liczba_kopiarek, data$Czas, xlab="Liczba obsługiwanych kopiarek", ylab = "Czas obsługi", col =
```

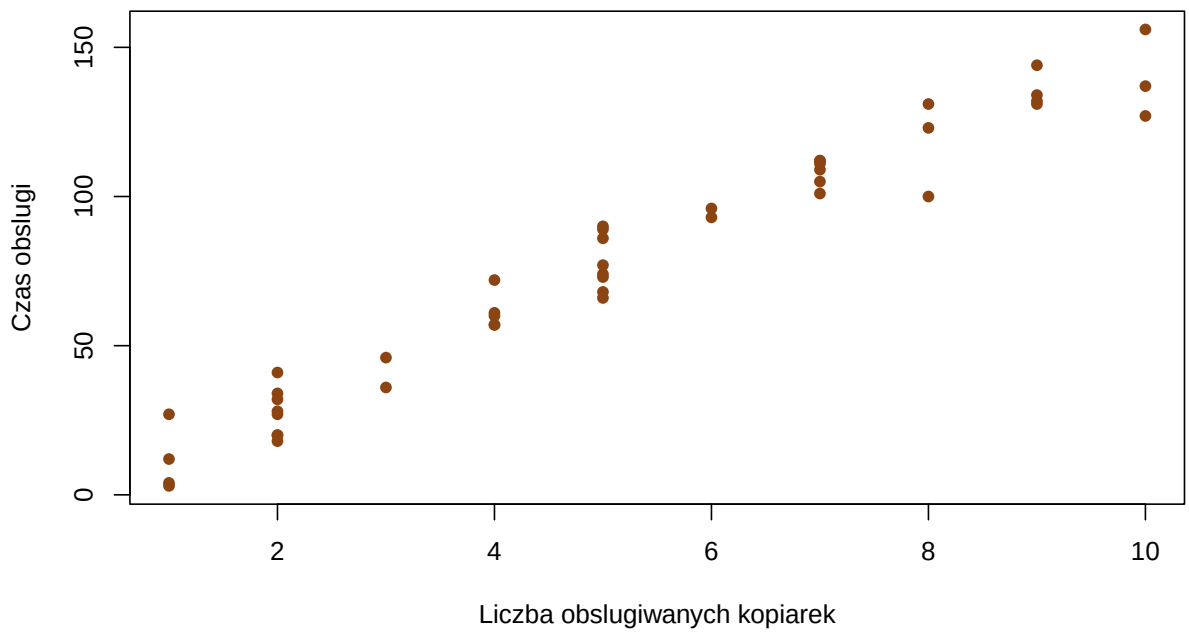

Gdy spojrzymy na powyższe punkty, bez problemu jesteśmy w stanie zauważyć ich liniowość. Dla coraz większej liczby kopiarek, zwiększa się również czas potrzebny do ich obsługi.

2 Zadanie 2.

Aby wyznaczyć estymowaną regresję liniową tych danych, potrzebujemy dwóch parametrów β_1 - później nazywany slope oraz β_0 - później nazwany intercept. Możemy ich estymowane wartości wyznaczyć w R na dwa sposoby - teoretyczny i korzystając z funkcji wbudowanych. W pierwszej kolejności zajmę się ich teoretycznym wyznaczaniem, a następnie wykorzystam wbudowane w R funkcje. Na koniec zaprezentuję dwa wykresy z prostą regresji liniowej, żeby widoczne było, że obie proste zostały wyznaczone poprawnie.

Wzory teoretyczne na wyliczenie slope oraz intercept prezentują się następująco:

$$\hat{\beta}_1 = \frac{\sum_{i=1}^{n}(X_i - \bar{X})(Y_i - \bar{Y})}{\sum_{i=1}^{n}(X_i - \bar{X})^2}$$

$$\hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{X}$$

gdzie X_i to kolejne dane z kolumny przedstawiającej liczbę kopiarek, a Y_i to dane z kolumny czasu obsługi. $\bar{X}$ oraz $\bar{Y}$ to średnie tych zmiennych.

Poniżej umieszczam kod, obliczający slope oraz intercept właśnie z powyższych wzorów.

```
x <- data$Liczba_kopiarek
y <- data$Czas
xmean <- mean(x)
ymean <- mean(y)
slope_t <- sum((x - xmean)*(y - ymean))/sum((x - xmean)**2)
intercept_t <- ymean - slope_t * xmean
```

Z kolei funkcje, które umożliwiają wyliczenie tego bezpośrednio w R są to `lm(Y~X, data=data)`, która wylicza m.in. właśnie potrzebny nam intercept oraz slope. Dokładne wyliczenie można zovbaczyć poniżej.

```
colnames(data) <- c("Y", "X")
ml <- lm(Y~X, data=data)
intercept_r <- ml$coefficients[1]
slope_r <- ml$coefficients[2]
```

Teraz narysuję oba wykresy, aby były widoczne obie proste regresji liniowej. Ta wyliczona ze wzorów teoretycznych będzie zaznaczona kolorem czerwonym, a ta wyliczona za pomocą komendy w R - kolorem zielonym.

```
colnames(data) <- c("Czas", "Liczba_kopiarek")
par(mfrow=c(1, 2))
plot(data$Liczba_kopiarek, data$Czas, xlab="Liczba obsługiwanych kopiarek", ylab = "Czas obsługi", col =
abline(a = intercept_t, b = slope_t, col = "red", lwd=2)
plot(data$Liczba_kopiarek, data$Czas, xlab="Liczba obsługiwanych kopiarek", ylab = "Czas obsługi", col =
abline(a = intercept_r, b = slope_r, col = "green", lwd=2)
```

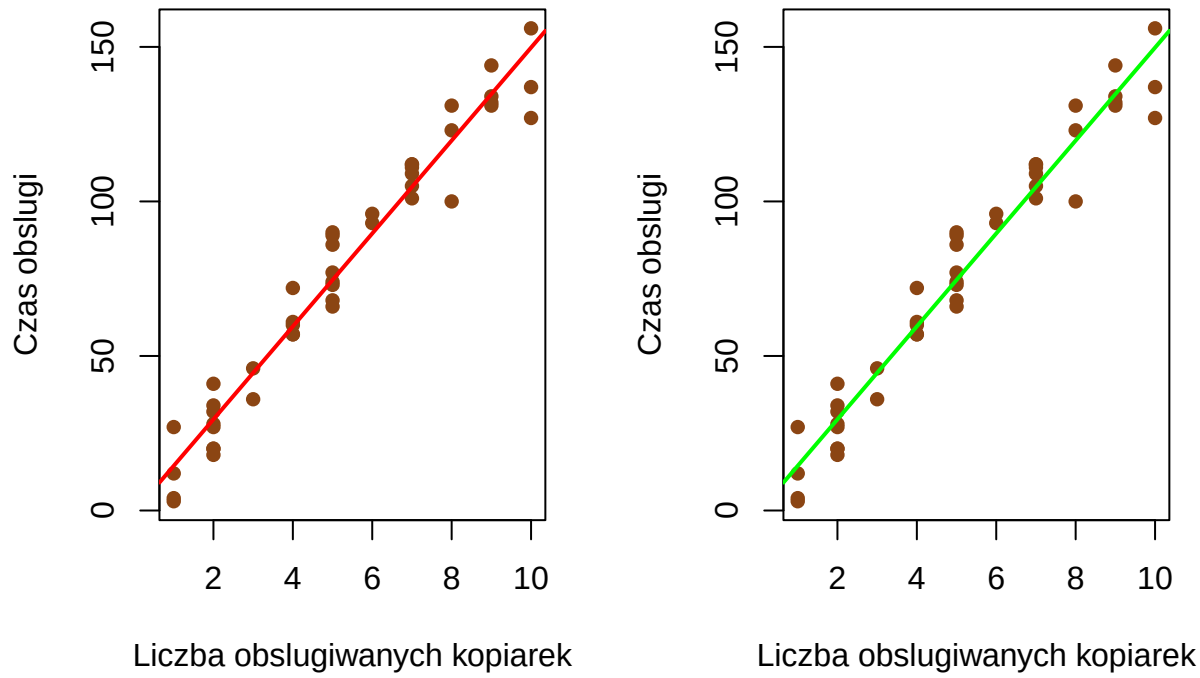

Można zauważyć na poniższych wykresach, że obie wartości zostały wyliczone poprawnie. Widać, że znajdują się w tym samym miejscu i dzięki nim można lepiej zobaczyć liniowość badanych punktów.

3 Zadanie 3.

Aby wyznaczyć 95% przedział ufności dla slope'a oraz intersepta również można skorzystać z dwóch sposobów - licząc ze wzorów teoretycznych oraz za pomocą kodów w R. W pierwszej kolejności, podobnie jak wcześniej, zajmę się tym pierwszym sposobem. Wykorzystam do niego wyliczone również z wzorów teoretycznych wartości estymatorów slope'a oraz intersepta.

Zacznę od przedziału ufności dla slope'a. Ponieważ $\hat{\beta}_1 \sim N(\beta_1, \sigma^2(\hat{\beta}_1))$, gdzie $\sigma^2(\hat{\beta}_1) = \frac{\sigma^2}{\sum_{i=1}^n (X_i - \bar{X})^2}$ to przedział ufności o współczynniku ufności $1-\alpha$ przy nieznanym parametrze $\sigma^2(\hat{\beta}_1)$ ma postać

$$\hat{\beta}_1 \pm t_c s(\hat{\beta}_1)$$

gdzie t_c jest to kwantyl rzędu $1 - \frac{\alpha}{2}$ rozkładu t-studenta z $n-2$ stopniami swobody, a $s(\hat{\beta}_1)$ to pierwiastek kwadratowy z

$$s^2(\hat{\beta}_1) = \frac{s^2}{\sum_{i=1}^n (X_1 - \bar{X})^2}$$

gdzie $s^2 = \frac{1}{n-2} \sum_{i=1}^n (Y_i - \hat{\beta}_0 - \hat{\beta}_1 X_i)^2$.

Z kolei dla intercepta, $\hat{\beta}_0 \sim N(\beta_0, \sigma^2(\hat{\beta}_0))$, gdzie $\sigma^2(\hat{\beta}_0) = \sigma^2(\frac{1}{n} + \frac{\bar{X}^2}{\sum_{i=1}^n (X_i - \bar{X})^2})$ przedział ufności o współczynniku ufności $1-\alpha$ przy nieznanym parametrze $\sigma^2(\hat{\beta}_0)$ wyznacza się podobnie jako

$$\hat{\beta}_0 \pm t_c s(\hat{\beta}_0)$$

gdzie t_c to, tak jak wcześniej, kwantyl rzędu $1 - \frac{\alpha}{2}$ rozkładu t-studenta z $n-2$ stopniami swobody, a $s(\hat{\beta}_0)$ to pierwiastek kwadratowy z

$$s^2(\hat{\beta}_0) = s^2(\frac{1}{n} + \frac{\bar{X}^2}{\sum_{i=1}^{n}(X_i - \bar{X})^2})$$

gdzie s^2 jest takie samo jak wyżej.

```
n <- nrow(data)
alfa <- 0.05
s <- 1/(n-2) * sum((y - intercept_t - slope_t*x)**2)
sb1 <- s/(sum((x-xmean)**2))
t_c <- qt(1-(alfa/2), n-2)
slope_t_1 <- slope_t - t_c * sqrt(sb1)
slope_t_2 <- slope_t + t_c * sqrt(sb1)
sb0 <- s * (1/n + (xmean**2)/(sum((x-xmean)**2)))
intercept_t_1 <- intercept_t - t_c * sqrt(sb0)
intercept_t_2 <- intercept_t + t_c * sqrt(sb0)
```

Powyższe kody są zapisanymi w R obliczeniami. Przedziały ufności z nich wyliczone wynoszą [14.0610098, 16.0094863] dla slope'a oraz [-6.2348428, 5.0745295] dla intercepta.

Z kolei komendą w R, wydającą oba przedziały ufności, jest `confint`, w którą wpisujemy wynik `lm(Y~X, data=data)` wyliczony wyżej.

```
przedzialy <- confint(ml)
intercept_r_1 <- przedzialy[1, 1]
intercept_r_2 <- przedzialy[1, 2]
slope_r_1 <- przedzialy[2, 1]
slope_r_2 <- przedzialy[2, 2]
```

Dla wyliczeń przy pomocy konkretnej komendy w R przedziały ufności to [14.0610098, 16.0094863] dla slope'a oraz [-6.2348428, 5.0745295] dla intercepta, czyli dokładnie takie same wyniki, jak dla wyliczeń teoretycznych.

4 Zadanie 4.

W tym zadaniu mamy wykonać test istotności dla β_0 oraz β_1. Zaczniemy od tego drugiego.

W teście istotności hipoteza zerowa (H_0) to $\beta_1 = 0$, z kolei hipoteza alternatywna (H_A) sytuacja alternatywna $\beta_1 \neq 0$.

Statystyka testowa jest wtedy postaci

$$T = \frac{\hat{\beta}_1 - 0}{s(\hat{\beta}_1)}$$

gdzie $s(\hat{\beta}_1)$ jest takiej samej postaci jak w poprzednim zadaniu. Odrzucamy H_0, gdy $|T| > t_c$, gdzie t_c jest również takie samo jak w poprzednim zadaniu. Z kolei p-wartość jest to $P(|z| > |T|)$, gdzie $z \sim t(n-2)$.

W poniższym kodzie przedstawiam wyliczenie tego testu razem z p-wartością ze wzorów teoretycznych podanych wyżej.

```
T_slope_t <- slope_t/sqrt(sb1)
p_value_s_t <- 2 * (1 - pt(abs(T_slope_t), df=n-2))
```

Wykonanie porównania $|T| > t_c$ daje odpowiedź TRUE, zatem możemy odrzucić H_0. P-wartościami zajmę się później.

Dla β_0 test jest analogiczny, z $H_0 : \beta_0 = 0$ i $H_A : \beta_0 \neq 0$, więc umieszczę poniżej jedynie teoretyczne kody.

```
T_intercept_t <- intercept_t/sqrt(sb0)
p_value_i_t <- 2 * (1 - pt(abs(T_intercept_t), df=n-2))
```

Można tutaj zobaczyć, że wpisanie $|T| > t_c$ daje wartość FALSE, zatem nie możemy odrzucić H_0.

Z kolei konkretnym kodem w R, który pozwala na wykonanie zarówno testu istotności slope'a i intercepta, jak i wyznaczenie p-wartości jest funkcja `summary`, w którą wpisujemy zmienną wyliczoną wcześniej przez `lm(Y~X, data=data)`. Wyodrębniając z `summary cofficcients[,4]` dostajemy dokładnie p-wartość, natomiast patrząc jedynie na `coefficients[,3]` otrzymujemy statystyki testowe.

```
sum <- summary(ml)
T_intercept_r <- sum$coefficients[1,3]
T_slope_r <- sum$coefficients[2,3]
p_value_i_r <- sum$coefficients[1,4]
p_value_s_r <- sum$coefficients[2,4]
```

Sprawdźmy najpierw statystyki testowe. Wartości statystyki testowej dla slope'a i intercepta wyliczone teoretycznie wynoszą odpowiednio31.1232581 oraz -0.2069076, a te same statystyki testowe wyliczone przy użyciu kodów wbudowanych w R to kolejno 31.1232581 oraz -0.2069076. Widać, że mają one taką samą wartość.

Spójrzmy teraz na p-wartości. Dla wyliczeń teoretycznych kolejno dla slope'a i intercepta wynoszą 0 oraz 0.8370587. Natomiast te same statystyki wyliczone przez konkretne komendy w R to $4.0090321 \times 10^{-31}$ oraz 0.8370587. Jak widać, dla intercepta wartości są dokładnie takie same, jednak dla slope'a przy wyliczeniach teoretycznych otrzymujemy 0. Może to być spowodowane tym, że ta p-wartość (co można zobaczyć po wyliczeniu za pomocą konkretnej komendy w R) jest bardzo mała, na tyle mała, że R może ją zaokrąglić do 0 w powyższych obliczeniach.

5 Zadanie 5.

W tym zadaniu chcemy wyliczyć estymator i przedział ufności dla czasu obsługi kopiarek przy k liczbie obsługiwanych maszyn. Estymator wylicza się ze wzoru

$$\hat{\mu}_h = \hat{\beta}_0 + \hat{\beta}_1 k$$

Ponieważ $\hat{\mu}_h \sim N(\mu_h, \sigma^2(\hat{\mu}_h))$, gdzie $\sigma^2(\hat{\mu}_h) = \sigma^2(\frac{1}{n} + \frac{(k-\bar{X})^2}{\sum_{i=1}^n (X_i-\bar{X})^2})$ (σ^2 takie samo jak wcześniej) to przedział ufności można wyliczyć przy pomocy rozkładu t-studenta. Wynosi on wtedy:

$$\hat{\mu}_h \pm t_c s(\hat{\mu}_h)$$

gdzie $s^2(\hat{\mu}_h) = s^2(\frac{1}{n} + \frac{(k-\bar{X})^2}{\sum_{i=1}^n (X_i-\bar{X})^2})$, a t_c jest takie jak wcześniej.

Poniższa funkcja `est_confint_t` pozwala na wyliczenie właśnie tego estymatora i tych przedziałów ufności, przy podstawieniu pewnego k.

```r
est_confint_t <- function(k)
{
  est <- intercept_t + slope_t*k
  s_2 <- s*(1/n + (k-xmean)^2/sum((x-xmean)^2))
  right <- est + t_c*sqrt(s_2)
  left <- est - t_c*sqrt(s_2)
  return(c(est, left, right))
}

k <- c(1, 5, 8, 11, 25, 100)
values_t <- sapply(k, est_confint_t)
```

Z kolei aby obliczyć to samo przy pomocy funkcji wbudowanych w R, korzystam z funkcji `predict(ml, k, interval="confidence")`, gdzie `ml` to zapisane wcześniej `lm(Y~X, data=data)`. Kod znajduje się poniżej.

```r
k <- data.frame(X=k)
values_r <- predict(ml, k, interval="confidence")
```

Aby zobaczyć, że dla obu wyliczeń wyniki są takie same, zaprezentuję je w tabeli.

k	Estymator teoretycznie	Estymator R	Przedział ufności teoretycznie	Przedział ufności R
$k = 1$	14.4550914	14.4550914	[9.6361398, 19.274043]	[9.6361398, 19.274043]
$k = 5$	74.5960836	74.5960836	[71.9142236, 77.2779435]	[71.9142236, 77.2779435]
$k = 8$	119.7018277	119.7018277	[115.8157148, 123.5879406]	[115.8157148, 123.5879406]
$k = 11$	164.8075718	164.8075718	[158.4754398, 171.1397038]	[158.4754398, 171.1397038]
$k = 25$	375.3010444	375.3010444	[355.7401136, 394.8619751]	[355.7401136, 394.8619751]
$k = 100$	1502.9446475	1502.9446475	[1410.4614362, 1595.4278588]	[1410.4614362, 1595.4278588]

W powyższej tabeli można zauważyć, że wszystkie wartości dla obu wyliczeń są takie same, więc obliczenia zamieszczone w kodach są, najprawdopodobniej, poprawne.

Analizując tabelę, można zauważyć, że dla coraz większych wartości parametru k, przedziały ufności robią się coraz dłuższe. W pierwszych trzech wierszach ($k = 1$, $k = 5$ oraz $k = 8$) przedziały ufności mają dość małą długość (odpowiednio około 10, 6, 8). Dla $k = 1$ jest to dość długi przedział, jeśli patrzymy na niego pod względem liczb, które się w nim znajdują.

Można jednak zauważyć, że długość przedziału ufności jest tym dłuższa, im dalej znajduje się od znanych danych zapisanych w badanym pliku.

6 Zadanie 6.

Celem tego zadania jest podanie przewidywanego czasu obsługi k serwisowanych maszyn oraz przedziału predykcyjnego dla tego czasu.

Przewidywany czas obsługi określa się wzorem

$$\hat{Y}_h = \hat{\mu}_h = \hat{\beta}_0 + \hat{\beta}_1 X_h$$

zatem dokładnie taki sam, jak estymator wyliczany w poprzednim zadaniu. Jest to spowodowane faktem, że nie potrafimy modelować zachowania ϵ, czyli błędu losowego, który znajduje się we wzorze.

Główna zmiana przy przedziale predykcyjnym polega na tym, że zmienia się wariancja dla błędu predykcji. Wynosi ona

$$\sigma^2(pred) = \sigma^2(1 + \frac{1}{n} + \frac{(X_h - \bar{X})^2}{\sum_{i=1}^{n}(X_i - \bar{X})^2})$$

dla σ^2 takiego jak wyżej.

Przedział predykcyjny ma postać

$$\hat{\mu}_h \pm t_c s(pred)$$

gdzie $s(pred)$ jest pierwiastkiem kwadratowym z $s^2(pred) = s^2(1 + \frac{1}{n} + \frac{(X_h - \bar{X})^2}{\sum_{i=1}^{n}(X_i - \bar{X})^2})$, gdzie s^2 jest takie, jak wcześniej.

Poniższy kod przedstawia te wyliczenia w funkcji `est_predint_t`, która wydaje nam przewidywany czas obsługi oraz wyliczony przedział predykcyjny.

```
est_predint_t <- function(k) {
  est <- intercept_t + slope_t * k
  s_pred_2 <- s * (1 + 1/n + ((k - xmean)**2)/(sum((x - xmean)**2)))
  right <- est + t_c * sqrt(s_pred_2)
  left <- est - t_c * sqrt(s_pred_2)
  return(c(est, left, right))
}

k <- c(1, 5, 8, 11, 25, 100)
values_pred_t <- sapply(k, est_predint_t)
```

Z kolei gdy chcemy wykorzystać komendy wpisane w R, możemy użyć tej samej funkcji `predict()` tym razem wpisując `interval = "prediction"`. Otrzymamy wtedy przedział predykcyjny.

```
k <- data.frame(X=k)
values_pred_r <- predict(ml, k, interval="prediction")
```

Zaprezentuję teraz wyniki w tabeli, aby móc zobaczyć, czy są one takie same dla obu sposobów, a także w jaki sposób wielkość k wpływa na rozmiar przedziału predykcyjnego.

k	Przewidywany czas teoretycznie	Przewidywany czas R	Przedział predykcyjny teoretycznie	Przedział predykcyjny R
$k = 1$	14.4550914	14.4550914	[-4.155437, 33.0656198]	[-4.155437, 33.0656198]
$k = 5$	74.5960836	74.5960836	[56.421325, 92.7708421]	[56.421325, 92.7708421]
$k = 8$	119.7018277	119.7018277	[101.3107606, 138.0928947]	[101.3107606, 138.0928947]
$k = 11$	164.8075718	164.8075718	[145.7490994, 183.8660442]	[145.7490994, 183.8660442]

k	Przewidywany czas teoretycznie	Przewidywany czas R	Przedział predykcyjny teoretycznie	Przedział predykcyjny R
$k = 25$	375.3010444	375.3010444	[348.7349102, 401.8671786]	[348.7349102, 401.8671786]
$k = 100$	1502.9446475	1502.9446475	[1408.7306685, 1597.1586266]	[1408.7306685, 1597.1586266]

W powyższej tabeli można zauważyć, że wyliczone wartości przewidywanego czasu oraz przedziały predykcyjne są takie same dla obu sposobów ich liczenia.

Jak można z łatwością zauważyć, przedziały predykcyjne mają dość dużą długość (najkrótszy ma długość około 35, a najdłuższy niecałe 200). Ponownie, najdłuższy przedział jest dla największego k zatem można założyć, że przedział predykcyjny jest tym dłuższy, im dalej od badanego zbioru znajduje się liczba.

7 Zadanie 7.

Teraz wykonam tabelę aby porównać przedział ufności do przedziału predykcyjnego.

k	Przedział ufności	Przedział predykcyjny
$k = 1$	[9.6361398, 19.274043]	[-4.155437, 33.0656198]
$k = 5$	[71.9142236, 77.2779435]	[56.421325, 92.7708421]
$k = 8$	[115.8157148, 123.5879406]	[101.3107606, 138.0928947]
$k = 11$	[158.4754398, 171.1397038]	[145.7490994, 183.8660442]
$k = 25$	[355.7401136, 394.8619751]	[348.7349102, 401.8671786]
$k = 100$	[1410.4614362, 1595.4278588]	[1408.7306685, 1597.1586266]

Jak widać w powyższej tabeli wszystkie przedziały są dłuższe, jeśli badamy przedziały predykcyjne, w porównaniu do przedziałów ufności. Im większa jest wielkość k tym bardziej zbliżone do siebie zą jego wartości.

Przedział predykcyjny jest większy od przedziału ufności, ponieważ większa jest wartość wariancji. $\sigma^2(pred)$ ma dodaną dodatkową jedynkę w nawiasie, w porównaniu do $\sigma^2(\hat{\mu}_h)$. Zatem przy liczeniu szerokości przedziału będzie można zobaczyć dużą różnicę między tymi dwoma przedziałami, właśnie z powodu wielkości tego parametru.

8 Zadanie 8.

8.1 Moc testu

Moc testu jest to prawdopodobieństwo uniknięcia błędu drugiego rodzaju, a zatem prawdopodobieństwo odrzucenia hipotezy zerowej, gdy jest fałszywa. W naszym przypadku zatem, gdy $\beta_1 \neq 0$. W takim wypadku moc testu przedstawia się jako $P(odrzucenie\ H_0|\beta_1 \neq 0)$, co można zapisać również jako $P(odrzucenie\ H_0|\beta_1 = 1)$, ponieważ znamy prawdziwą wartość β_1 i wynosi ona właśnie 1.

Hipotezę zerową odrzucamy, gdy statystyka testowa T wpada do obszaru krytycznego. Zatem prawdopodobieństwo, które mamy wyliczyć, to $P(|T| > t_c|\beta_1 = 1)$, co można zapisać również jako $P_{\beta_1=1}(|T| > t_c)$.

Aby wyliczyć moc testu potrzebujemy $\sigma^2(\hat{\beta}_1) = \frac{\sigma^2}{SSX}$, gdzie $SSX = \sum_{i=1}^{n}(X_i - \bar{X})^2$. Statystyka testowa T ma w tym przypadku rozkład t-studenta z $n-2$ stopniami swobody i parametrem niecentralności $\delta = \frac{\beta_1}{\sigma(\hat{\beta}_1)}$. Moc testu wynosi więc:

$$\pi(1) = P_{\beta_1=1}(|T| > t_c) = P_{\beta_1=1}(T < -t_c) + 1 - P(T < t_c)$$

Poniższy kod przedstawia to wyliczenie dla $n = 40, \sigma^2 = 70, SSX = 500$

```
n <- 40
sigma_2 <- 70
SSX <- 500
alpha <- 0.05
df <- n - 2
beta1 <- 1
tc <- qt(1-alpha/2,df)
sigma_2_b1 <- sigma_2/SSX
delta = beta1/sqrt(sigma_2_b1)
power <- 1 - pt(tc, df, delta) + pt(-tc, df, delta)
```

Z powyższych wyliczeń moc testu wynosi 0.740405. Nie jest to najlepszy wynik, zazwyczaj oczekujemy mocy testu od 80 w górę, aby zminimalizować szansę na błąd II rodzaju. W tym przypadku prawdopodobieństwo na ten błąd wynosi około 26. Nie jest to bardzo dużo, jednak daje ryzyko błędu. Jest to więc akceptowalna moc testu, jednak mogłaby być problematyczna, gdybyśmy robili badania, w których zależałoby nam na wykryciu nawet małych elementów.

8.2 Wykres

W tej części zadania 8, zapresentuję wykres mocy testu dla wartości slope'a β_1 między -2 a 2.

```
beta1 <- seq(from = -2, to = 2, by = 0.05)
delta = beta1/sqrt(sigma_2_b1)
power <- 1 - pt(tc, df, delta) + pt(-tc, df, delta)
plot(beta1, power, type='l', ylim = c(0,1), lwd = 2, col = "darkblue", xlab = "Wartość slope'a", ylab =
abline(h = 0.05, col = "red4", lwd = 2)
```

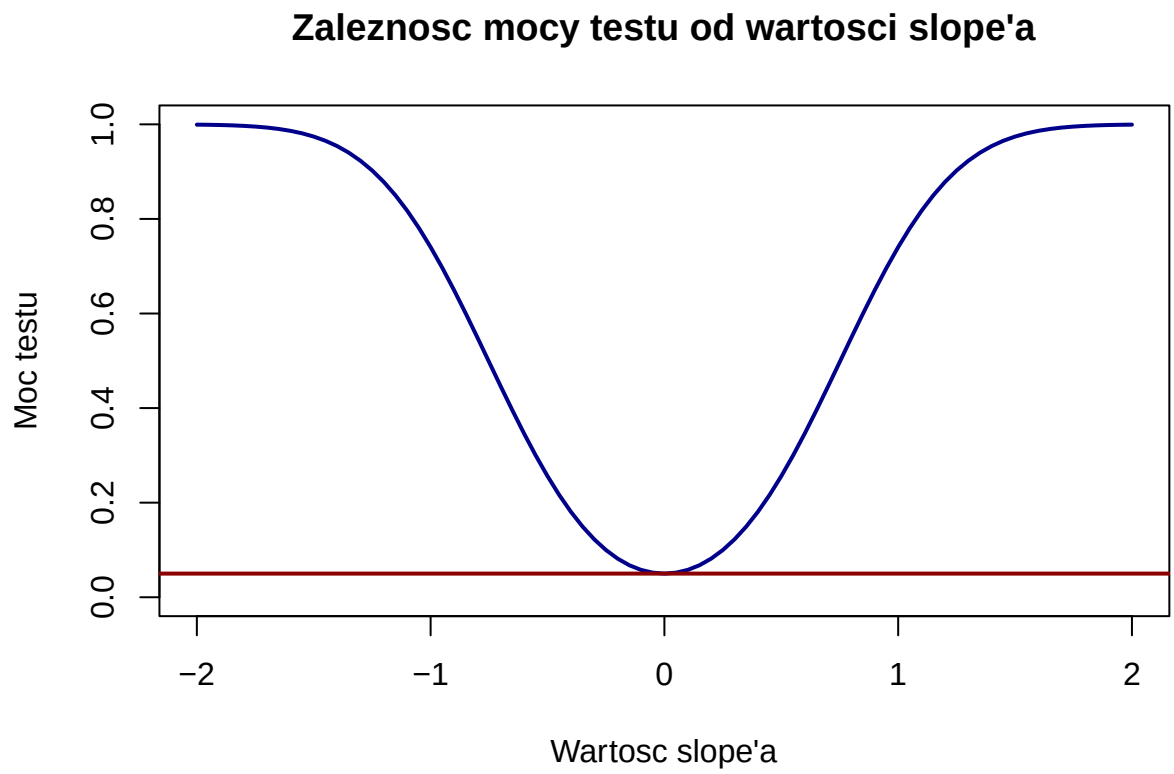

Jak można zauważyć na powyższym wykresie, dla wartości $\beta_1 = 0$ moc testu jest najmniejsza, wynosi tyle, co $\alpha = 0.05$, co widać przez czerwoną prostą $y = 0.05$. Moc testu zwiększa się, im dalej wartość parametru β_1 znajduje się od wartości 0. Dla punktów granicznych $\beta_1 = -2$ oraz $\beta_1 = 2$ moc testu wynosi prawie 100%.

Jest to zrozumiałe. Prawdopodobieństwo odrzucenia $H_0 : \beta_1 = 0$ zwiększa się, im dalej jesteśmy od wartości $\beta_1 = 0$, ponieważ dalsza od 0 będzie wtedy estymacja tego parametru.

Porównam teraz powyższy wykres z wykresem dla $\sigma^2 = 120$.

```
beta1 <- seq(from = -2, to = 2, by = 0.05)
sigma_2_b1_120 <- 120/SSX
delta = beta1/sqrt(sigma_2_b1_120)
power_120 <- 1 - pt(tc, df, delta) + pt(-tc, df, delta)
plot(beta1, power, type='l', ylim = c(0,1), lwd = 2, col = "darkblue", xlab = "Wartość slope'a", ylab =
lines(beta1, power_120, type='l', col = "plum4", lwd = 2)
legend("bottomright", legend = c(expression(sigma^2 == 70), expression(sigma^2 == 120)), col = c("darkbl
```

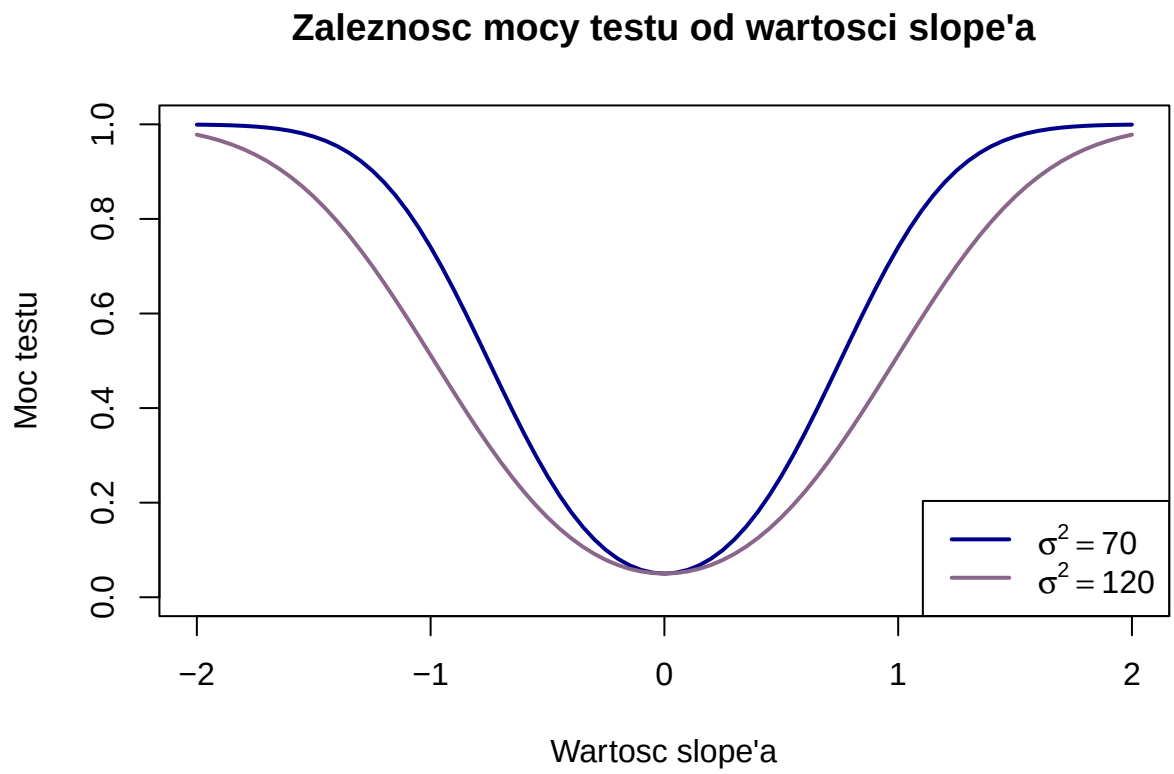

Gdy zwiększymy wartość parametru σ^2 z $\sigma^2 = 70$ do $\sigma^2 = 120$ możemy zauważyć pogorszenie się mocy testu, szczególnie w pobliżu punktu 0. Wynika z tego, że trudniej jest wykryć niewielkie odstępstwa od 0 w prawdziwej wartości parametru β_1, gdy zwiększamy wariancję.

Wciąż jednak moc testu jest bardzo wysoka (i zwiększa się) im dalej od 0 się znajdujemy. Dla wartości $\beta_1 = -2$ oraz $\beta = 2$ oraz tym znajdującym się w ich pobliżu różnica w mocy testu jest niewielka dla obu wykresów i jej wartość wynosi około 100.

9 Zadanie 9.

To zadanie polega na zbadaniu, jak rozkład szumu ϵ oraz wartości parametru β_1 wpływają na moc testu oraz błąd I rodzaju. W tym celu wygeneruję wektor losowy $X = (X_1, ..., X_{200})^T$ z rozkładu normalnego wielowymiarowego $N(0, \frac{1}{500}I)$, który później wykorzystam to wygenerowania tysiąca wektorów $Y = 5 + \beta_1 X + \epsilon$.

```
set.seed(1)
X <- rnorm(200, 0, 1/sqrt(500))
```

9.1 $\beta_1 = 0, \epsilon \sim N(0, I)$

Poniższa funkcja pozwala na przeprowadzenie testu dla podanej wartości β_1. Ponieważ $\alpha = 0.05$, to sprawdzamy, kiedy P-wartość jest mniejsza właśnie 0.05. Otrzymujemy z tego wartość TRUE, jeśli odrzucamy H_0 lub FALSE, jeśli tego nie robimy.

```r
pv9ad <- function(beta)
{
  beta1 <- beta
  epsilon <- rnorm(200)
  Y <- 5 + beta1*X + epsilon
  model <- lm(Y ~ X)
  pvalue <- summary(model)$coefficients[2,4]
  return(pvalue < 0.05)
}
```

Po powyższych wyliczeniach, wyznaczę średnią powtórzonej 1000 razy funkcji za pomocą komendy `replicate`, a następnie przyrównam do prawdziwej wartości błędu I rodzaju, która wynosi tyle samo co przyjęta wartość α, a zatem 0.05. Takie działanie powtórzę 3 razy aby móc porównać do siebie wyniki każdego z losowań. Poza tym, uniknę wtedy błędnego wnioskowania z jednego wyjątkowo udanego (lub wyjątkowo nieudanego) losowania.

Prawdziwa wartość	Losowanie 1.	Losowanie 2.	Losowanie 3.
0.05	0.049	0.05	0.043

Można zobaczyć, że te wartości w każdym przypadku są bardzo bliskie prawdziwej wartości błędu I rodzaju. Różnice wynoszą odpowiednio 0.001, 0 oraz 0.007, zatem bardzo niewiele. Można więc stwierdzić, że gdy $\epsilon \sim N(0, I)$ to nie ma on wpływu na prawdopodobieństwo odrzucenia H_0, gdy $\beta_1 = 0$

9.2 $\beta_1 = 0, \epsilon_1, ..., \epsilon_{200}$ iid z rozkładu wykładniczego $Exp(1)$

W tym przypadku, również tworzę funkcję, analogiczną do tej z podpunktu (a), ze znaczącą różnicą w wartości parametru `epsilon`, który tym razem będzie wyznaczany poprzez generowanie próby rozmiaru 200 z rozkładu wykładniczego (za pomocą funkcji `rexp`), w przeciwieństwie do rozkładu normalnego (i komendy `rnorm`) wykorzystanych w poprzednim podpunkcie. Całość funkcji można zobaczyć poniżej.

```r
pv9be <- function(beta)
{
  beta1 <- beta
  epsilon <- rexp(200)
  Y <- 5 + beta1*X + epsilon
  model <- lm(Y ~ X)
  pvalue <- summary(model)$coefficients[2,4]
  return(pvalue < 0.05)
}
```

Podobnie jak poprzednio przy pomocy komendy `replicate` wygeneruję wyniki powyższej funkcji 1000 razy, a następnie porównam z prawdziwą wartością błędu I rodzaju. Ponieważ ponownie wartość α wynosi 0.05, to nie zmienia się błąd I rodzaju w stosunku do poprzedniego podpunktu. Wyniki trzech losowań również przedstawię w tabeli.

Prawdziwa wartość	Losowanie 1.	Losowanie 2.	Losowanie 3.
0.05	0.039	0.053	0.048

W tym przypadku możemy zauważyć, że różnica między prawdziwą wartością błędu I rodzaju, a estymowanym prawdopodobieństwem odrzucenia H_0 jest nieco większa niż w poprzednim przypadku. Nie jest

to jednak znacząca różnica. Wynosi ona kolejno 0.011, 0.003 oraz 0.002. Można więc stwierdzić, że dla ϵ z rozkładu wykładniczego estymacja nieco się psuje, ale dalej jest akceptowalna.

9.3 $\beta_1 = 0, \epsilon_1, ..., \epsilon_{200}$ iid z rozkładu logistycznego $L(0, 1)$

Ponownie, poniższa funkcja różni się od poprzednich jedynie wartością zmiennej `epsilon`, w której w tym przypadku kryje się wygenerowana za pomocą formuły `rlogis(200)` dwustuelementowa próba z rozkładu logistycznego z parametrami 0 oraz 1. Dokładną formę funkcji można zauważyć w poniższym kodzie.

```
pv9cf <- function(beta)
{
  beta1 <- beta
  epsilon <- rlogis(200)
  Y <- 5 + beta1*X + epsilon
  model <- lm(Y ~ X)
  pvalue <- summary(model)$coefficients[2,4]
  return(pvalue < 0.05)
}
```

Również jak w poprzednich podpunktach, wygeneruję pewną próbę wielkości 1000 przy pomocy powyższej funkcji oraz komendy `replicate`, a następnię wyliczę średnią, którą ponownie przyrównam do $\alpha = 0.05$, wyznaczającego naszą teoretyczną wartość błędu pierwszego rodzaju. Znów powtórzę to 3 razy, aby wyniki były widoczne w tabeli.

Prawdziwa wartość	Losowanie 1.	Losowanie 2.	Losowanie 3.
0.05	0.068	0.06	0.055

Gdy spojrzymy na tę tabelę, możemy zauważyć, że występuje tu najgorszy estymator. Jest to ten dla pierwszego losowania, który różni się aż o 0.018 od prawdziwej wartości błędu pierwszego rodzaju. Pozostałe różnią się kolejno o 0.06 oraz 0.005. Można więc stwierdzić, że dla ϵ_i z rozkładu logistycznego $L(0, 1)$ można zauważyć znaczne pogorszenie się estymacji dla niektórych losowań.

Można więc założyć, że gdy $\beta_1 = 0$ estymowane prawdopodobieństwo odrzucenia hipotezy zerowej $H_0 : \beta_1 = 0$ pogarsza się, gdy ϵ_i pochodzi z rozkładu wykładniczego $Exp(1)$ lub rozkładu logistycznego $L(0, 1)$.

9.4 $\beta_1 = 2, \epsilon \sim N(0, 1)$

W tym przypadku skorzystam ze stworzonej przeze mnie wcześniej funkcji `pv9ad`, podstawiając pod niego zmienną $\beta_1 = 2$. Powtórzę to trzykrotnie.

Aby móc wykonać zadanie w tym przypadku muszę obliczyć moc testu, potrzebną również do pozostałych dwóch podpunktów. Moc testu wyliczam dla $\beta_1 = 2$, w ten sam sposób, co w poprzednich zadaniach. Kod umieszczę poniżej.

```
n <- 200
s_2 <- 1
ssx <- sum((X-mean(X))^2)
alpha <- 0.05
beta1 <- 2
s_2_b1 <- s_2/ssx
df <- n-2
```

```r
tc <- qt(1-alpha/2,df)
delta <- beta1/sqrt(s_2_b1)
power <- 1 - pt(tc,df,delta) + pt(-tc,df,delta)
```

W celu porównania do siebie prawdziwej wartości mocy testu, oraz przybliżonego prawdopodobieństwa odrzucenia hipotezy zerowej, wyniki powyższych wyliczeń umieszczę w tabeli.

Prawdziwa wartość	Losowanie 1.	Losowanie 2.	Losowanie 3.
0.2146679	0.216	0.209	0.208

Jakie można wyciągnąć wnioski z powyższych wyników? Przede wszystkim widać, że dla każdego losowania wartość przybliżonego prawdopodobieństwa odrzucenia $H_0 : \beta_1 = 0$ jest zbliżone do prawdziwej wartości mocy testu. Nie jest to idealne przybliżenie, ale nie różni się od prawdziwej wartości wiele.

Warto również zauważyć, że teoretycznie wyliczona wartość mocy testu jest stosunkowo mała. Jest to spowodowane tym, że wartość β_1 również jest stosunkowo mała, więc testowanie rzadko będzie przynosiło dobre efekty.

9.5 $\beta_1 = 2, \epsilon_1, ..., \epsilon_{200}$ iid z rozkładu wykładniczego $Exp(1)$

W tym przypadku wykorzystuję funkcję z podpunktu (b) tego zadania (a zatem funkcję `pv9be`), a także moc testu wyliczoną w poprzednim podpunkcie. Wyniki w tabeli prezentują się następująco.

Prawdziwa wartość	Losowanie 1.	Losowanie 2.	Losowanie 3.
0.2146679	0.229	0.22	0.235

Gdy spojrzymy na wyniki, w pierwszej chwili możemy zauważyć, że są znacznie gorsze od tych wyliczonych, gdy $\epsilon \sim N(0, I)$. W tym przypadku, szczególnie w 3 losowaniu, wartości są oddalone od prawdziwej wartości mocy testu. Wciąż są jednak one akceptowalne.

9.6 $\beta_1 = 0, \epsilon_1, ..., \epsilon_{200}$ iid z rozkładu logistycznego $L(0, 1)$

W tym przypadku, wykorzystam funkcję z podpunktu (c) `pv9cf`, w którą wstawię wartość $\beta_1 = 2$. Wyniki trzykrotnego losowania umieszczę w tabeli, wraz z prawdziwą wartością mocy testu wyliczoną wcześniej.

Prawdziwa wartość	Losowanie 1.	Losowanie 2.	Losowanie 3.
0.2146679	0.109	0.093	0.099

Z powyższej tabeli możemy przede wszystkim wyczytać, że w tym przypadku, wyestymowane wartości są bardzo dalekie od prawdziwej wartości mocy testu. Zatem, gdy $\beta_1 = 2$, można stwierdzić, że ϵ_i o rozkładzie logistycznym znacznie "psuje" estymator prawdopodobieństwa odrzucenia H_0, w porównaniu do poprzednich dwóch przykładów. W żadnym badanym z sześciu przypadków w tym zadaniu nie nastąpiło tak złe przybliżenie, jak w tym powyżej.

10 Zadanie teoretyczne

10.1 95% przedział ufności dla β_1

Jak zaznaczyłam w zadaniu 3. przedział ufności o współczynniku ufności $1-\alpha$ przy nieznanym $\sigma^2(\hat{\beta}_1)$, a z takim przypadkiem mamy do czynienia w tym zadaniu, ma postać

$$\hat{\beta}_1 \pm t_c s(\hat{\beta}_1)$$

gdzie t_c to kwantyl rzędu $1-\frac{\alpha}{2}$ rozkładu t-studenta z $n-2$ stopniami swobody. W tym przypadku t_c to kwantyl rzędu 0.975 z 18 stopniami swobody i wynosi on 2.101, co można odczytać z tablic statystycznych rozkładu t-studenta.

Wiedząc, że $s(\hat{\beta}_1) = s(b_1) = 1$ oraz $\hat{\beta}_1 = b_1 = 3$, można obliczyć, że przedział ufności dla β_1 wynosi:

$$3 \pm 1 \cdot 2.101$$

$$1 \pm 2.101$$

co można również zapisać jako

$$[3-2.101, 3+2.101]$$

$$[0.899, 5.101]$$

co daje nam ostateczny wynik.

10.2 Czy istnieje statystyczne uzasadnienie dla twierdzenia, że Y zależy od X?

Aby móc odpowiedzieć na to pytanie należy zrobić test istotności dla hipotezy zerowej $H_0 : \beta_1 = 0$ oraz hipotezy alternatywnej $H_A : \beta_1 \neq 0$. Gdy odrzucimy hipotezę zerową (a zatem β_1 będzie statystycznie istotna) będziemy mogli to traktować, jako statystyczne uzasadnienie, że Y zależy od X.

W tym zadaniu wykorzystam teorię opisaną przeze mnie w zadaniu 4. Statystyka testowa ma wzór $T = \frac{b_1-0}{s(b_1)}$, gdzie b_1 to estymowana wartość β_1 podana w poleceniu. Gdy podstawimy znane nam wartości wychodzi, że $T = 3$. Wynika z tego, że $|T| > t_c$, ponieważ t_c to ta sama wartość, co w poprzednim podpunkcie i wynosi 2.101.

Zatem odrzucamy hipotezę zerową na rzecz hipotezy alternatywnej. Oznacza to, że wartość β_1 jest statystycznie istotna, a zatem Y zależy od X, czego statystycznym uzasadnieniem jest powyższy test istotności.

10.3 Przedział predykcyjny dla E(Y), gdy znany jest przedział ufności

Z polecenia wynika, że przedział ufności dla E(Y), gdzie $X = 5$ wynosi $[13, 19]$. Wzory teoretyczne biorę tym razem z tych zawartych w zadaniu 5. (przedział ufności) oraz zadaniu 6. (przedział predykcyjny). E(Y) będę w dalszej części oznaczać jako $\hat{\mu}_h$, aby zachować zgodność z oznaczeniami na wykładzie.

Przedział ufnośći różni się od przedziału predykcyjnego wartością $s(\hat{\mu}_h)$. Dla przedziału ufności wynosi ona pierwiastek z $s^2(\hat{\mu}_h) = s^2(\frac{1}{n} + \frac{(X_h-\bar{X})^2}{\sum_{i=1}^{n}(X_i-\bar{X})^2}$, gdzie według naszego polecenia $X_h = 5$. Z kolei przedział predykcyjny jest pod pierwiastkiem o s^2 większy.

Obliczmy więc w pierwszej kolejności $s^2(\hat{\mu}_h)$ dla przedziału ufności. Wychodzi nam z tego:

$$2t_c s(\hat{\mu}_h) = 19 - 13$$

$$2 \cdot 2.101 \cdot s(\hat{\mu}_h) = 6$$

$$s(\hat{\mu}_h) = \frac{6}{4.202} \approx 1.43$$

Zatem kwadrat tej wartości wynosi

$$s^2(\hat{\mu}_h) \approx 2.0449$$

Z tego względu ta wartość dla przedziału predykcyjnego przy podanym w poleceniu $s = 4$ to:

$$s^2(pred) = s^2 + s^2(\hat{\mu}_h) = 4^2 + 2.0449 = 18.0449$$

Możemy teraz utworzyć przedział predykcyjny:

$$\hat{\mu}_h \pm t_c s(pred) = 1 + 3 \cdot 5 \pm 2.101 \cdot \sqrt{18.0449}$$

$$[\hat{\mu}_h - t_c s(pred), \hat{\mu}_h + t_c s(pred)] = [16 - 8.93, 16 + 8.93]$$

Zatem ostatecznie przedział predykcyjny wynosi w zaokrągleniu:

$$[7.07, 24.93]$$