Lista 4. ModeleLiniowe

Amelia Olejniczak

Contents

1 Zadanie 1. **2**

1.1 Generowanie macierzy X oraz wektora zmiennej odpowiedzi Y 2

1.2 Przedział ufności dla wartości β_1 oraz t-test 2

1.3 Odchylenie standardowe estymatora β_1 oraz moc identyfikacji X_1 3

1.4 1000 różnych zmiennych odpowiedzi 3

2 Zadanie 2. **4**

2.1 Generowanie macierzy X oraz wektora odpowiedzi Y 4

2.2 Estymacja wartości współczynników regresji, t-testy oraz istotne informacje o modelu zbudowanym z k pierwszych kolumn macierzy planu 4

2.3 Powtórzenie gdy modele są konstruowane dla zmiennych o największych estymowanych współczynnikach regresji 7

2.4 Powtórzenie rozumowań z poprzednich dwóch podpunktów dla powtórzenia losowania 1000 razy 8

1 Zadanie 1.

1.1 Generowanie macierzy X oraz wektora zmiennej odpowiedzi Y

Do wykonania tego zadania potrzebujemy biblioteki `mvtnorm`, w której mamy możliwość generowania wielowymiarowych rozkładów normalnych. Poniżej przedstawiam kod, w którym generuję macierz X.

```
sigma <- matrix(c(1, 0.9, 0.9, 1), ncol = 2)
X <- rmvnorm(100, c(0, 0), sigma/100)
```

Jak można zauważyć, do wygenerowania macierzy X wykorzystuję funkcję `rmvnorm`, która jest dość intuicyjna w działaniu. Teraz przedstawię sposób generowania wektora zmiennej odpowiedzi $Y = \beta_1 X_1 + \epsilon$, wartości zmiennych jak w poleceniu.

```
epsilon <- rnorm(100, 0, 1)
Y <- 3 * X[,1] + epsilon
```

Jego wygenerowanie jest ponownie dość intuicyjne, podobnie jak poprzednie wygenerowanie macierzy X.

1.2 Przedział ufności dla wartości β_1 oraz t-test

Przedział ufności przy poziomie istotności $\alpha = 0.05$ dla wartości β_1 oraz t-test przy hipotezie zerowej $H_0 : \beta_1 = 0$ wyliczę dwoma sposobami. W każdym z nich wykorzystam wygenerowane wcześniej wartości macierzy X oraz wektora zmiennej odpowiedzi.

1.2.1 Przy użyciu modelu prostej regresji liniowej $Y = \beta_0 + \beta_1 X_1 + \epsilon$

W pierwszej kolejności użyję modelu prostej regresji liniowej $Y = \beta_0 + \beta_1 X_1 + \epsilon$. Poniżej przedstawiam kod, służący do wyliczenia przedziału ufności dla β_1 dla tego modelu.

```
lm_1 <- lm(Y ~ X[,1])
ci_1 <- confint(lm_1, level = 0.95)[2, ]
```

Z powyższego kodu wychodzi, że 95% przedział ufności wynosi $[0.705, 4.74]$.

Teraz zajmę się t-testem. Wyliczę p-wartość i na jej podstawię określę, czy są przesłanki do odrzucenia H_0.

```
p_val_1 <- summary(lm_1)$coefficients[2, 4]
```

Bazując na p-wartości, która z powyższych kodów wynosi około 0.0087, możemy odrzucić H_0.

1.2.2 Przy użyciu modelu z dwiema zmiennymi objaśniającymi $Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \epsilon$

Spróbujmy teraz ponowić obliczenia, korzystając z modelu wielorakiego, z dwiema zmiennymi objaśniającymi. Kody są analogiczne, z różnicą polegającą na zmianie modelu. Tym razem korzystamy z modelu wyznaczonego w kodzie `lm(Y ~ X[,1] + X[,2])`. Ze względu na zmiany jedynie kosmetyczne, w tym przypadku kodu nie będę umieszczać.

Zacznijmy od przedziału ufności, który w tym przypadku wynosi $[-1, 92, 7.23]$. Można zauważyć, że jest on znacznie szerszy niż w przypadku prostej regresji liniowej. Jest to związane z wysoką korelacją w macierzy korelacji. X_1 oraz X_2 są ze sobą skorelowane powoduje wzrost wariancji β_1.

Zajmijmy się teraz t-testem dla β_1. Wyliczenie p-wartości zachodzi w analogiczny sposób jak poprzednio, zatem kodu nie umieszczam.

P-wartość dla tego przypadku wynosi 0.2523, a zatem znacznie więcej niż $\alpha = 0.05$. Tutaj nie można odrzucić H_0, a zatem w tym przypadku dodatkowa zmienna objaśniająca wpływa nie tylko na szerokość przedziału ufności, ale również na wynik testu istotności. W poprzednim przypadku wyszło, że β_1 nie jest istotne, a tutaj nie możemy wysnuć takich wniosków. Jest to spowodowane, ponownie, korelacją w macierzy korelacji, a więc związkiem między X_1 oraz X_2.

1.3 Odchylenie standardowe estymatora β_1 oraz moc identyfikacji X_1

W tej części, zajmę się obliczeniem odchylenia standardowego estymatora β_1. Wariancję oblicza się ze wzoru

$$Var(\beta_1) = \sigma^2(\mathbb{X}'\mathbb{X})^{-1}_{22}$$

Ze względu na to, że $\sigma^2 = 1$ to wzór prezentuje się jako

$$Var(\beta_1) = (\mathbb{X}'\mathbb{X})^{-1}_{22}$$

gdzie $\mathbb{X}$ jest to macierz eksperymentu.

Z kolei moc identyfikacji X_1 jest możliwa do wywnioskowania na podstawie mocy poprzedniego testu. Moc testu wyraża się wzorem

$$\pi = P_{\beta_1=3}(|T| > t_c)$$

gdzie T to statystyka testowa, t_c to kwantyl rozkładu t-studenta o $n - p$ stopniach swobody dla $1 - \frac{\alpha}{2}$.

Poniżej umieszczam kod, w którym krok po kroku obliczam zarówno odchylenie standardowe (będące pierwiastkiem kwadratowym z wariancji) oraz moc testu, z której wywnioskuję moc identyfikacji X_1. Kod Dotyczy jedynie modelu prostej regresji liniowej, ponieważ dla regresji liniowej z dwoma zmiennymi objaśniającymi kod jest analogiczny.

```
mp_1 <- matrix(1, nrow = 100, ncol = 2)
mp_1[,2] <- X[,1]
sd_1 <- sqrt(solve(t(mp_1)%*%mp_1)[2,2])
tc_1 <- qt(1-0.05/2, 100-2)
delta_1 <- 3/sd_1
power_1 <- pt(-tc_1, 100-2, delta_1) + 1 - pt(tc_1, 100-2, delta_1)
```

W pierwszej kolejności spójrzmy na odchylenie standardowe parametru β_1. Wynosi ono odpowiednio 0.958 dla prostej regresji liniowej oraz 2.162 dla regresji liniowej z dwoma zmiennymi objaśniającymi. Jak widać, zgodnie z tym, o czym mówiłam wcześniej, odchylenie standardowe w drugim przypadku jest znacznie większe niż w pierwszym przypadku.

Z kolei moc testu wynosi odpowiednio 87.3% oraz 27.93%. Widać w tym przypadku, że moc drugiego testu jest znacznie mniejsza niż pierwszego.

W jaki sposób moc testu jest związana z mocą identyfikacji X_1? Otóż w przypadku, gdy moc testu jest mała, można wnioskować o tym, że moc identyfikacji X_1 również jest niska. Jest to równoznaczne z tym, że trudno jest zidentyfikować wpływ X_1 na Y niezależnie od X_2. Ponownie, powodem jest wysoka korelacja.

1.4 1000 różnych zmiennych odpowiedzi

Na koniec tego zadania powtórzę 1000 razy losowanie wektora błędów losowych ϵ oraz na jego podstawie wygeneruję 1000 wektorów Y. Następnie wyestymuję wartości odchylenia standardowego β_1 oraz mocy testu. Poniżej przedstawiam stworzoną przeze mnie funkcję z której będę korzystać.

```r
sd_pow <- function(X)
{
  epsilon <- rnorm(100, 0, 1)
  beta1 <- 3
  Y <- beta1 * X[,1] + epsilon

  lm_1 <- lm(Y ~ X[,1])
  lm_2 <- lm(Y ~ X[,1] + X[,2])

  b1_1 <- lm_1$coefficients[2]
  b1_2 <- lm_2$coefficients[2]

  p_val_1 <- summary(lm_1)$coefficients[2, 4]
  p_val_2 <- summary(lm_2)$coefficients[2, 4]
  return(c(b1_1, b1_2, p_val_1 < 0.05, p_val_2 < 0.05))
}
```

W tej funkcji otrzymujemy 4 wartości - estymowana wartość β_1 dla obu modeli oraz wartość `TRUE` lub `FALSE` w zależności od tego, czy odrzucone jest H_0. Na podstawie tego możemy wyestymować odchylenie standardowe oraz moc testu.

Spójrzmy najpierw na odchylenie standardowe. Estymowane wartości tego odchylenia wynoszą odpowiednio 0.9762 dla prostego modelu oraz 2.1145 dla drugiego z nich. Dla przypomnienia - teoretyczne wartości wynoszą 0.9581 oraz 2.1622 zatem bardzo sobie bliskie.

Przyjrzyjmy się teraz mocy testu. Estymowane wartości wynoszą 0.871 dla prostego modelu oraz 0.278 dla modelu z dwiema zmiennymi objaśniającymi. Teoretyczne wartości wynoszą tutaj odpowiednio 0.873 oraz 0.2793. Ponownie można zobaczyć, że wartości estymowane są bardzo bliskie wartościom teoretycznym.

2 Zadanie 2.

2.1 Generowanie macierzy X oraz wektora odpowiedzi Y

W tym zadaniu mamy do czynienia z macierzą, której wymiary są dużo większe niż w poprzednim przypadku. Każdy element macierzy $X_{1000\times950}$ jest również niezależną od siebie zmienną losową. Wektor zmiennej odpowiedzi z kolei ma postać $Y = X\beta + \epsilon$, gdzie $\beta = (3, 3, 3, 3, 3, 0, ..., 0)^T$.

Poniżej w kodzie przedstawiam sposób na generowanie takiej macierzy.

```r
X <- matrix(rnorm(1000*950, 0, 0.1), nrow = 1000, ncol = 950)
beta <- c(replicate(5, 3), replicate(945, 0))
epsilon <- rnorm(1000, 0, 1)
Y <- X%*%beta + epsilon
```

2.2 Estymacja wartości współczynników regresji, t-testy oraz istotne informacje o modelu zbudowanym z k pierwszych kolumn macierzy planu

W tej części raportu zajmę się estymacją wartości współczynników regresji oraz wykonam t-testy na poziomie istotności 0.05 w celu zidentyfikowania istotnych regresorów. Będę to powtarzać dla modeli zbudowanych z k pierwszych kolumn macierzy planu, gdzie $k \in \{1, 2, 5, 10, 50, 100, 500, 950\}$.

Poniżej prezentuję funkcję, w której wyznaczę:

- sumę kwadratów residiów $SSE = ||Y - \hat{Y}||^2$;
- błąd średniokwadratowy estymatora wartości oczekiwanej Y: $MSE = ||X(\hat{\beta} - \beta)||$;
- wartość kryterium AIC: $AIC = n \log(SSE/n) + 2k$;
- p-wartości dla dwóch pierwszych zmiennych objaśniających;
- liczbę fałszywych odkryć;

```r
f <- function(X, Y, k, beta){
  X_k <- X[, 1:k, drop = F]
  lm_k <- lm(Y ~ X_k - 1)

  b_hat <- summary(lm_k)$coefficients[,1]
  p_val <- summary(lm_k)$coefficients[,4]

  Y_hat <- X_k %*% b_hat
  SSE <- sum((Y-Y_hat)^2)

  MSE <- sum((X_k %*% (b_hat - beta[1:k]))^2)

  AIC <- 1000 * log(SSE/1000) + 2*k

  if(k==1)
  {
    p_val_2 <- c(p_val[1], NA)
  }
  else
  {
    p_val_2 <- p_val[1:2]
  }

  if(k<=5)
  {
    fo <- 0
  }
  else
  {
    fo <- sum(p_val[(6:k)] <= 0.05)
  }

  return(c(SSE, MSE, AIC, p_val_2[1], p_val_2[2], fo))
}
```

Powyższy kod sprowadza się do wyliczenia wszystkich potrzebnych wartości, o które proszono w zadaniu. Estymatory parametru β oraz p-wartość są wyznaczone za pomocą `summary()$coefficients`. Pozostałe wartości zostały wyliczone ze znanych wzorów.

Warto zaznaczyć, czym są fałszywe odkrycia. Jest to równoznaczne z błędem pierwszego rodzaju. Ponieważ naszą hipotezą zerową jest $H_0 : \beta_k = 0$ to w pierwszych pięciu przypadkach odrzucenie H_0 będzie poprawne (dla przypomnienia - $\beta_k = 3$ dla pierwszych 5 przypadków). Dlatego dla k <= 5 liczba fałszywych odkryć będzie równa 0.

Wyniki z funkcji dla k podanych w poleceniu przedstawię w tabeli. Następnie przeanalizuję jej wartości.

k	SSE	MSE	AIC	p-wartości dla dwóch pierwszych zmiennych objaśniających	Liczba fałszywych odkryć
1	1360.2658883	3.4058898	309.6801867	$1.2665418 \times 10^{-10}$, brak	0
2	1248.3363238	4.3336038	225.8117239	$4.0377297 \times 10^{-12}$, 2.143296×10^{-20}	0
5	1000.9705871	4.3931911	10.9701164	$6.4386691 \times 10^{-16}$, $7.3067712 \times 10^{-24}$	0
10	997.2393019	8.1244763	17.2354842	$8.3224084 \times 10^{-16}$, $1.8577831 \times 10^{-23}$	0
50	954.1181598	51.2456184	53.0322421	1.383571×10^{-14}, $1.4133049 \times 10^{-22}$	2
100	923.8188912	81.544887	120.7607683	$1.0736472 \times 10^{-13}$, $3.0600793 \times 10^{-20}$	4
500	510.1295376	495.2342406	326.9094097	8.8995487×10^{-7}, $2.8669258 \times 10^{-14}$	29
950	49.5587362	955.805042	-1104.5967227	0.3918589, 0.0957129	21

Na podstawie powyższej tabeli można zauważyć, że dla coraz większych wartości k, SSE jest coraz mniejsze. Z kolei MSE oraz liczba fałszywych odkryć wzrastają, przeciwnie do wcześniej wspomnianego SSE. Warto również się przyjrzeć od razu p-wartości. W znacznej większości przypadków są one dużo mniejsze od $\alpha = 0.05$. Jedynym przypadkiem, w którym p-wartości są znacznie większe od $\alpha = 0.05$ jest w ostatnim wierszu, a zatem dla $k = 950$.

Przeanalizujmy teraz, który model powinniśmy wybrać, na podstawie wartości AIC. Najmniejsza wartość tego kryterium jest dla największego $k = 950$. Wynikałoby z tego, że jest to najlepszy wybór modelu. Nie można jednak zignorować przy tym powyższej analizy, gdzie MSE oraz liczba fałszywych odrzuceń jest bardzo duża. Podobnie dwie p-wartości, które w znaczący sposób odbiegają od pozostałych widocznych w tabeli. Wynika z tego, że najlepszym modelem byłby jeden z następnych dwóch, gdy ustawimy je rosnąco względem AIC. Byłby to wtedy model z $k = 5$ lub $k = 10$. P-wartości są tutaj niemal identyczne, natomiast problematyczne przy $k = 950$ MSE jest dużo mniejsze (małe w obu przypadkach, jednak minimalnie mniejsze dla $k = 5$). Podobnie z liczbą fałszywych odrzuceń, która w obu przypadkach wynosi 0.

Wynika z tego, że model, dla którego $k = 5$ byłby najpewniej najlepszym wyborem.

2.3 Powtórzenie gdy modele są konstruowane dla zmiennych o największych estymowanych współczynnikach regresji

W tym przypadku musimy zapomnieć o wszystkim, co robiliśmy wcześniej. Aby wykonać to zadanie w pierwszej kolejności potrzebujemy posortować estymowane współczynniki regresji w kolejności od największego do najmniejszego. Aby to zrobić w pierwszej kolejności tworzę model ze wszystkimi kolumnami macierzy X, a następnie wyznaczę estymowane współczynniki regresji. Na koniec wyznaczam malejącą kolejność ich indeksów. Wszystkie te wyliczenia wykorzystuję później w funkcji, która będzie bardzo podobna do poprzedniej, zatem nie będę jej umieszczać w raporcie. Różnice będą polegała na dodadniu dodatkowej zmiennej do funkcji (`sort_index`, za który będzemy podstawiać indeksy ustawionych w kolejności rosnącej współczynników regresji). Następnie w funkcji określam `X_k` jako macierz X, z kolumnami stanowiącymi te, o pierwszych k indeksach zapisanych w `sort_index`.

Zmienia się również sposób wyliczania fałszywych odkryć teraz nie wiemy, na których miejscach znajdują się te wartości β_i, które wynosiły 3, a gdzie są zera. Wyliczamy zatem w pierwszej kolejności `fałszywe_odkrycia <- which(beta[indexes] == 0 & p_val <= 0.05)`, gdzie dostaniemy wiadomość o tym, w których miejscach znajdują się fałszywe odkrycia, a następnie `fo <- length(fałszywe_odkrycia)`, aby dowiedzieć się ile ich jest.

```r
lm_x <- lm(Y ~ X - 1)
beta_hat <- summary(lm_x)$coefficients[,1]
sort_index <- order(abs(beta_hat), decreasing = TRUE)
```

Poniżej przedstawiam tabelę, wykonaną dla tego samego X oraz Y, które wyliczaliśmy w podpunkcie a) tego zadania.

k	SSE	MSE	AIC	p-wartości dla dwóch pierwszych zmiennych objaśniających	Liczba fałszywych odkryć
1	1413.2911984	126.5857911	347.9211677	0.0747362, brak	0
2	1404.1983486	275.0101033	343.4665696	0.0781951, 0.0111675	1
5	1402.5453564	565.6688967	348.2886975	0.0757564, 0.0121667	1
10	1391.9049239	576.3093291	350.6732578	0.0697189, 0.01015	2
50	1159.9365365	808.2777165	248.3652937	0.0082586, 0.0125257	7
100	1004.5608328	963.6534202	204.5504637	0.0011493, 0.0144912	10
500	309.1116528	1659.1026002	-174.0527313	$7.6338336 \times 10^{-14}$, 4.9259829×10^{-7}	303
950	49.5587362	1918.6555168	-1104.5967227	0.007221, 0.0187474	21

Jak widać w powyższej tabeli, MSE oraz SSE zachowują się w ten sam sposób co w poprzedniej tabeli. Ważną różnicą, którą można tu jednak spostrzec jest fakt, że MSE jest dość duże nawet dla $k = 1$, a w szczególności znacznie większe niż w przypadku poprzedniej tabeli. P-wartości także mają zupełnie

inne wartości, większe niż w przypadku poprzedniego podpunktu (w szczególności - częściej odrzucana jest hipoteza zerowa). Fałszywych odkryć, szczególnie dla $k = 500$ jest dużo więcej niż w poprzednim przypadku.

Wartości kryteruim AIC również się różnią. Na pierwszy rzut oka wydają się być ułożone malejąco. Moglibyśmy więc wybrać ten z najmniejszym AIC, zatem ponownie $k = 950$, jednak nie byłoby to optymalne. Mimo, że fałszywych odkryć jest dużo mniej, to MSE jest jeszcze większe niż poprzednio. Druga najmniejsza wartość jest dla $k = 500$, natomiast jest wtedy dużo więcej fałszywych odkryć. Z tego względu, również bym ją wykluczyła. Z kolei trzecie w kolejności największe AIC (dla $k = 100$) zmaga się z tym samym problemem, co dla $k = 950$. Gdy przyjrzymy się wszystkim wierszom w tabeli możemy stwierdzić, że żadna wartość w niej zawarta nie nadaje się zbyt dobrze. Gdybym musiała jednak wybrać jedną to prawdopodobnie byłoby to $k = 2$. Ma ona niestety dość dużą wartość kryterium AIC w porównaniu do pozostałych (czwarta najmniejsza), jednak wszystkie pozostałe parametry są dużo mniejsze.

Warto jednak wziąć pod uwagę, że w tym przypadku, żaden z modeli nie wyróżnia się i nie jest bardzo dobry.

2.4 Powtórzenie rozumowań z poprzednich dwóch podpunktów dla powtórzenia losowania 1000 razy

Tym razem powtórzę powyższe rozumowania, gdy mam do czynienia z tysiącem różnych wektorów Y (stworzonych za pomocą znanych X oraz β, a także losowanych dla każdego oddzielnie ϵ). Kodu nie będę umieszczać, gdyż będę w nim korzystała z podanych wyżej funkcji.

Poniżej przedstawiam tabelę z wyliczeniami mocy identyfikacji X_1 i X_2 oraz średnia liczba fałszywych odkryć.

k	Moc identyfikacji X_1		Moc identyfikacji X_2		Średnia liczba fałszywych odkryć	
	b	**c**	**b**	**c**	**b**	**c**
1	1	0.528	NA	NA	0	0.055
2	1	0.525	1	0.331	0	0.124
5	1	0.526	1	0.336	0	0.372
10	1	0.527	1	0.337	0.269	0.863
50	1	0.555	1	0.383	2.241	4.996
100	1	0.604	1	0.445	4.746	11.723
500	1	1	1	1	24.987	290.165
950	0.619	0.999	0.457	0.997	46.963	46.963

Zacznijmy o analizę mocy identyfikacji w oparciu o powyższą tabelę. Dla podpunktu b wynosi ona 1 dla prawie wszystkich wartości poza $k = 950$ zarówno w przypadku X_1 jak i X_2. Z kolei dla największej próby jest ona niemal (lub ponad) o połowę mniejsza od wcześniej wspomnianej jedynki. Z kolei dla podpunktu c od $k = 1$ aż do $k = 100$ wartości wynoszą około 0.5, zatem podobnie jak dla największej wartości w podpunkcie b. Tutaj z kolei $k = 500$ oraz $k = 950$ są bardzo wysokie - wynoszą 1 lub nieco poniżej 1.

Spójrzmy teraz na średnią liczbę fałszywych odkryć. To, że dla podpunktu b w pierwszych 3 przypadkach wynosi ona 0 jest całkowicie spodziewane. Poniższe wartości wzrastają, co również jest efektem, który mogliśmy w pewnym stopniu spostrzec badając jedną próbę. Z kolei w podpunkcie c również możemy zauważyć wzrost, który kończy się jednak w momencie, gdy $k = 500$, potem następuje gwałtowny spadek. Jest to również zgodne z poprzednim rozumowaniem.

W przypadku wyboru AIC podjęłam decyzję, aby nie patrzeć na $k = 950$, gdyż w kilku sprawdzonych przeze mnie przypadkach, za każdym razem to ona była najmniejsza. Wezmę więc pod uwagę wartości k mniejsze od 950 (a dla podpunktu c również dla k innych od 500), gdyż na podstawie poprzednich rozumowań wiemy, że te modele nie są tak naprawdę zbyt dobre.

W przypadku podpunktu b średnia wynosi 5.43, a dla podpunktu c 67.584. Wybór k jest więc dużo większy, gdy mamy do czynienia z największymi estymowanymi wartościami β. Z kolei w podpunkcie b potrzebne są dużo mniejsze wartości.