Analiza metod regulacyjnych dla różnych macierzy planu

Amelia Olejniczak

Wprowadzenie

Poniższy raport dotyczy analizy metod regulacyjnych. Skupimy się w nim na regresji grzbietowej oraz na estymatorze LASSO, a następnie również adaptacyjnym LASSO, w którym parametry wyznaczymy przy użyciu dwóch różnych wag. Zobaczymy, która z tych metod minimalizuje MSE, a następnie, korzystając dodatkowo również z techniki knockoffów, przyjrzymy się w jaki sposób kontrolują one FDR oraz moc tych procedur w każdym przypadku, porównując z pozostałymi wyliczonymi estymatorami. Przebadamy przypadek ortonormalny, a także taki, gdzie elementy macierzy planu pochodzą z rozkładu normalnego.

Analiza dla ortonormalnej macierzy planu

W pierwszej kolejności przeanalizujemy, jak zachowuje się estymator uzyskany przy pomocy regresji grzbietowej oraz LASSO dla macierzy ortonormalnej. Przedstawię teoretyczne wzory na wyliczenie wariancji, obciążenia, oraz błędu średniokwadratowego w przypadku regresji grzbietowej. Poźniej przedstawię sposób na wyliczenie wartości γ oraz λ minimalizujących MSE (wraz z ich wartościami), a następnie porównam błędy średniokwadratowe dla metod regulacyjnych z tymi uzyskanymi dla estymatora najmniejszych kwadratów. Na koniec przedstawię uzyskaną teoretycznie liczbę fałszywych odkryć wraz z mocą identyfikacji zmiennych dla LASSO.

Symulacja danych

Aby przygotować dane do tego zadania, w pierwszej kolejności wygeneruję ortonormalną macierz planu X o wymiarach 500×500 przy pomocy funkcji `randortho()` z biblioteki `pracma`. Następnie wygeneruję takie wektory $Y = X\beta + \epsilon$, że $\epsilon \sim N(0, I_{500\times500})$, natomiast wektory β wyglądają następująco:

- $\beta_1 = ... = \beta_k = 4$, $\beta_{k+1} = ... = \beta_{500} = 0$
- $\beta_1 = ... = \beta_k = \sqrt{\frac{80}{k}}$, $\beta_{k+1} = ... = \beta_{500} = 0$

gdzie $k \in \{5, 20, 100\}$.

Otrzymamy w ten sposób sześć różnych wektorów zmiennej odpowiedzi, na podstawie których przeprowadzę analizę.

Teoretyczne wyliczenia

Mając przygotowane dane, zajmijmy się teoretycznymi wyliczeniami obciążenia, wariancji i błędu średniokwadratowego estymatora $\hat{\beta}_i$ uzyskanego przy pomocy regresji grzbietowej z parametrem wygładzającym γ. Jest to nam niezbędne, aby móc jak najlepiej porównać wartości MSE, dla każdego estymatora β

Wiemy, że $\hat{\beta}_{RR} \sim N\left((X'X+\gamma I)^{-1}X'X\beta, \sigma^2(X'X+\gamma I)^{-1}X'X(X'X+\gamma I)^{-1}\right)$ dzięki czemu od razu możemy wyznaczyć wariancję tego estymatora. W naszym przypadku macierz X jest ortonormalna, zatem $X'X = I$ oraz $\sigma^2 = 1$. Z tego wynika, że dla

$$Var(\hat{\beta}_{RRi}) = (1+\gamma)^{-1} \cdot 1 \cdot (1+\gamma)^{-1} = \frac{1}{(1+\gamma)^2}$$

Obciążenie również możemy wyliczyć bez większego problemu. Wiemy, że jest ono różnicą między wartością oczekiwaną estymatora, a prawdziwą wartością parametru. Zatem możemy zapisać, że jest to:

$$\mathbb{E}(\hat{\beta}_{RRi}) - \beta_i = \frac{1}{1+\gamma}\beta_i - \beta_i = -\frac{\gamma}{1+\gamma}\beta_i$$

Na koniec wyznaczmy teoretyczny wzór do wyliczenia MSE. Będzie to suma wartości błędu średniokwadratowego dla i-tych współrzędnej wektora beta, które wiemy, że jest sumą wariancji i kwadratu obciążenia dla tego estymatora. Zatem

$$MSE_i = \left(-\frac{\gamma}{1+\gamma}\beta_i\right)^2 + \frac{1}{(1+\gamma)^2} = \frac{\gamma^2}{(1+\gamma)^2}\beta_i^2 + \frac{1}{(1+\gamma)^2}$$

$$MSE(\hat{\beta}_{RR}) = \frac{\gamma^2||\beta||^2 + p}{(1+\gamma)^2}$$

Parametry γ oraz λ minimalizujące MSE

Zajmijmy się w pierwszej kolejności wyznaczeniem parametrów minimalizujących MSE dla regresji grzbietowej oraz LASSO.

Zaczynając od pierwszego z nich, możemy zobaczyć, że w celu wyznaczenia odpowiedniego MSE wystarczy znaleźć minimum funkcji $MSE(\hat{\beta}_{RR})$ wyznaczonej wyżej. Różniczkując powyższe równanie wzgędem parametru γ otrzymujemy

$$\frac{2\gamma||\beta||^2(1+\gamma)^2 + 2(p+\gamma^2||\beta||^2)(1+\gamma)}{(1+\gamma)^4}$$

Co po przyrównaniu do zera i odpowiednich przekształceniach daje nam

$$\gamma = \frac{p}{||\beta||^2}$$

Nietrudno sprawdzić, że w tym miejscu jest minimum. Dla potwierdzenia, poniższe wykresy pokazują MSE policzone dla parametrów γ między 0.01 a 50. Pionowa linia wskazuje wyliczone z powyższego wzoru γ. Oczekujemy zatem, że pionowa linia będzie przechodziła przez minimalną wartość na wykresie.

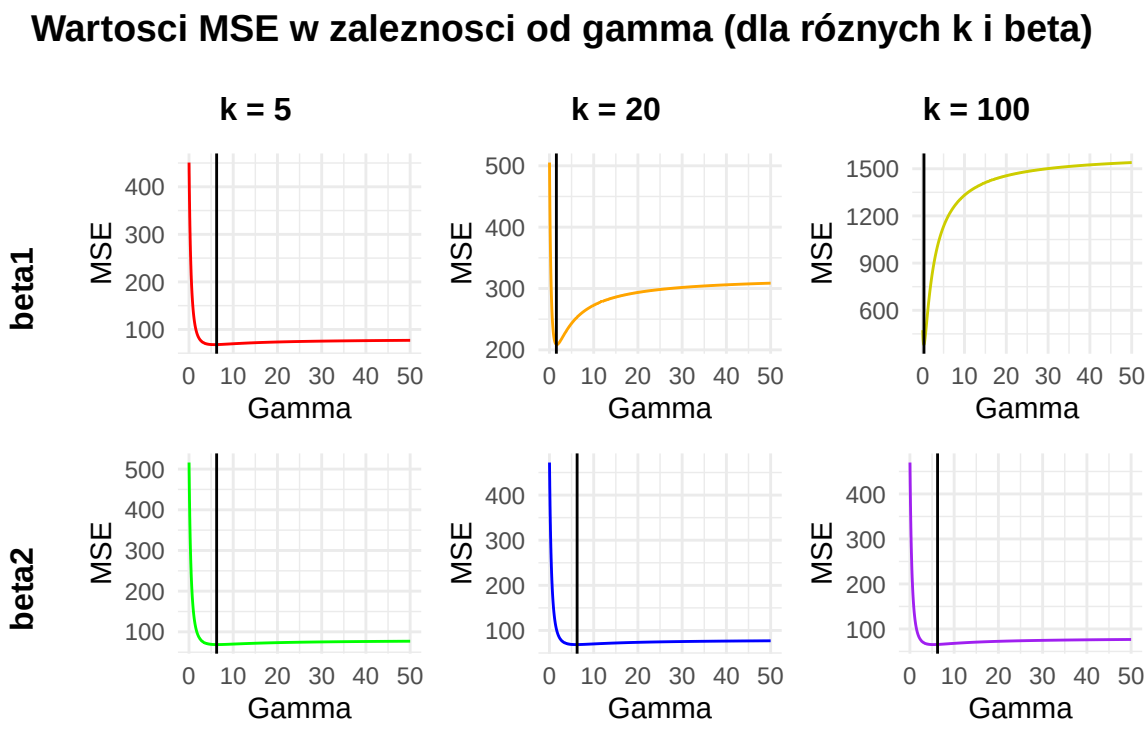

Gdy przyjrzymy się tym wykresom widać, że jest dokładnie tak, jak oczekiwaliśmy. Wartości wyliczonego γ znajdują się w miejscu, gdzie MSE jest minimalne. Poniżej w tabeli umieszczam zatem wartości γ dla poszczególnych k oraz typów β.

Table 1: Gamma minimalizujące MSE

	k = 5	k = 20	k = 100
i	6.25	1.5625	0.3125
ii	6.25	6.2500	6.2500

Jak widać w powyższej tabeli, wartości γ są stosunkowo duże. Co ciekawe, γ dla drugiego z wektorów β są takie same bez względu na wartość k. Jest to związane z tym, że $||\beta||^2$ jest równe bez względu na wartość k.

$$||\beta||^2 = \sum_{i=1}^{k} \left(\sqrt{\frac{80}{k}}\right)^2 = k * \frac{80}{k} = 80$$

W przypadku parametru λ dla LASSO nie będę wykorzystywać teoretycznych wzorów i zamiast tego posłużę się biblioteką `glmnet` i zapisaną w niej funkcją `glmnet`. Wczytując nasze dane do funkcji, odczytałam wektor dopasowanych do nich parametrów λ, następnie z odpowiedniego wzoru wyznaczyłam wartości MSE i wyszukałam wśród nich minimalną wartość, tym samym znajdując minimalizujące je λ. Poniżej przedstawiam wyniki tych symulacji, zamieszczone na odpowiednich wykresach.

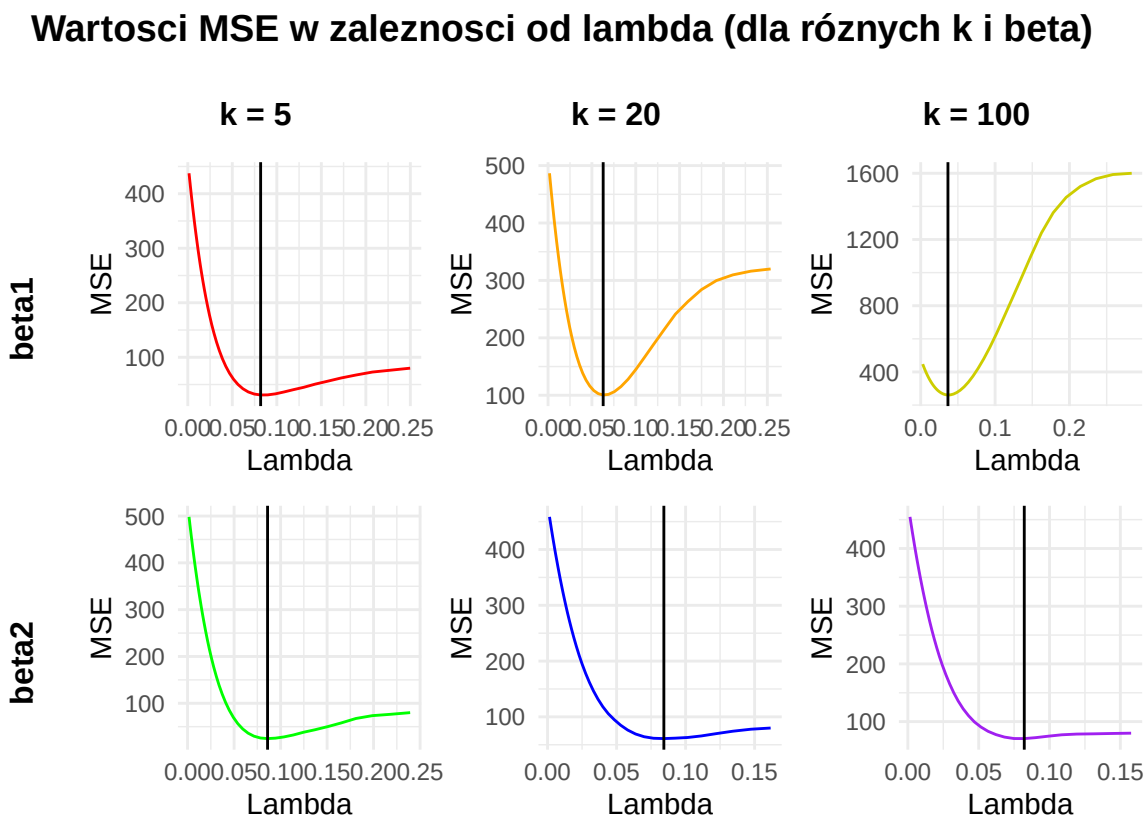

Można zobaczyć, że w symulacjach komputerowych otrzymaliśmy różne przedziały λ, zatem wykresy mają różną podziałkę. Nie jest to jednak dla nas problemem, gdyż wykresy pokazują nam jedynie, w podobny sposób jak poprzednie, w którym miejscu znajduje się wartość λ, która minimalizuje MSE. Widać, że nasze wyznaczenie tych wartości ponownie jest poprawne, a MSE przyjmuje minimalne wartości w miejscu pionowych linii. Spójrzmy teraz na tabelę z wwyznaczonymi wartościami λ, które możemy zobaczyć na powyższych wykresach.

Table 2: Lambda minimalizująca MSE

	k = 5	k = 20	k = 100
i	0.0817911	0.0628621	0.0366382
ii	0.0860126	0.0842660	0.0821570

Jak widać powyżej, wartości λ znajdujące się w tabeli są stosunkowo niewielkie. Podobnie jak wcześniej możemy również zauważyć, że wartości dla drugich z wektorów β są podobne do siebie, również podobne do najmniejszej wartości k przy pierwszych wektorach β wartość jest zbliżona do pozostałych. Jest to tendencja przypominająca tę dla γ, w której mogliśmy zobaczyć, że wartości w tych czterech miejscach w tabeli były takie same.

Wartości MSE

Powyższa analiza doprowadziła nas do porównania wyznaczonych wartości MSE dla trzech metod - regresji grzbietowej, LASSO oraz metody najmniejszych kwadratów. W ostatnim z przypadków MSE liczymy teoretycznie. Jak wcześniej wspominałam,

$$MSE = Bias^2 + Var(\hat{\beta})$$

Ze względu na to, że wiemy, że $Var(\hat{\beta_{LS}}) = \sigma^2 (X'X)^{-1}$, a $X'X = I$ (ponieważ X jest ortonormalna), a estymator najmniejszych kwadratów jest estymatorem nieobciążonym (zatem $Bias = 0$), to powyższy wzrór na MSE w naszym przypadku możemy uprościć do

$$MSE(\hat{\beta}_{LS}) = p\sigma^2$$

co bez względu na k oraz β wynosi 500, gdyż w naszym przypadku $\sigma^2 = 1$, a $p = 500$. Wartości MSE dla regresji grzbietowej możemy policzyć ze wzoru podanego wyżej, natomiast wartość dla LASSO będzie przybliżoną wartością, liczoną jako suma kwadratów różnicy między prawdziwą wartością β, a jej estymatorem.

Table 3: Porównanie MSE dla pierwszego typu beta

	LS	Ridge	LASSO
k = 5	500	68.12024	30.82372
k = 20	500	208.66365	100.45987
k = 100	500	382.19303	260.80172

Table 4: Porównanie MSE dla drugiego typu beta

	LS	Ridge	LASSO
k = 5	500	68.74212	24.54985
k = 20	500	68.72529	61.04200
k = 100	500	65.48896	70.59515

Jak widać powyżej, bez względu na wartości w wektorze β najlepiej sobie radzi metoda LASSO. To dla niej wartości MSE są najmniejsze, jednak w każdym przypadku widzimy poprawę w stosunku do wartości dla estymatora najmniejszych kwadratów. Warto również zauważyć, że dla drugiego typu parametru β wartości są dużo mniejsze.

Liczba fałszywych odkryć i moc identyfikacji dla LASSO

Na koniec analizy dla macierzy ortonormalnej zajmiemy się analizą liczby fałszywych odkryć i mocy identyfikacji dla metody LASSO. Jesteśmy w stanie je wyliczyć teoretycznie.

Jeśli chodzi o liczbę fałszywych odkryć, to będzie to liczba wszystkich niezerowych wartości (w naszym przypadku $500 - k$) pomnożona przez prawdopodobieństwo fałszywego odkrycia, które liczymy jako:

$$\mathbb{P}(\text{Fałszywe odkrycie}) = \mathbb{P}(\text{LASSO wybiera} X^j | \beta_j = 0) = \mathbb{P}\left(|\hat{\beta}^j_{LS}| > \lambda | \beta_j = 0\right)$$

Wiemy, że X jest ortonormalna, zatem $\hat{\beta}^j_{LS} \sim N(\beta^j, \sigma^2)$, stąd, jeśli $\beta^j = 0$, to $\hat{\beta}^j_{LS} \sim N(0, \sigma^2)$. Z tego względu musimy ustandaryzować zmienną, aby móc skorzystać z rozkładu standardowego normalnego. Wiemy jednak, że u nas $\sigma^2 = 1$ Zatem

$$\mathbb{P}\left(|\beta^j_{LS}| > \lambda | \beta_j = 0\right) = 2\left(1 - \Phi\left(\lambda\right)\right)$$

Z kolei moc identyfikacji jest prawdopodobieństwem poprawnego wskazania zmiennej niezerowej. Zatem w tym przypadku chcemy znaleźć prawdopodobieństwo

$$\mathbb{P}\left(|\hat{\beta}^j_{LS}| > \lambda | \beta^j = x\right)$$

gdzie $x = 4$ lub $x = \sqrt{\frac{80}{k}}$ w zależności od tego, z którym przypadkiem mamy do czynienia. Po przekształceniach (aby móc skorzystać z rozkładu standardowego normalnego) otrzymujemy

$$\mathbb{P}\left(\hat{\beta}^j_{LS} - x > \lambda - x\right) + \mathbb{P}\left(\hat{\beta}^j_{LS} - x < -\lambda - x\right) = (1 - \Phi(\lambda - x)) + \Phi(-\lambda - x)$$

W poniższych tabelkach umieszczam wyniki tych działań.

Table 5: FD dla LASSO

	k = 5	k = 20	k = 100
i	462.7324	455.9406	388.3094
ii	461.0709	447.7656	373.8088

Table 6: Moc identyfikacji dla LASSO

	k = 5	k = 20	k = 100
i	0.9999777	0.9999830	0.9999902
ii	0.9999777	0.9931986	0.9804054

Jak widać, bez względu na rozmiar i typ β fałszywych odkryć jest stosunkowo bardzo dużo. Podobnie jednak również moc identyfikacji dla LASSO jest bardzo wysoka. Wynika z tego zatem, że metoda LASSO pozwala na dobrą identyfikację istotnych zmiennych, kosztem identyfikacji wielu zmiennych nieistotnych.

Analiza dla macierzy planu o niezależnych zmiennych losowych z rozkładu normalnego

W ten części zajmiemy się analizą regresji grzbietowej oraz LASSO, podobnie jak poprzednio, jednak tym razem weźmiemy również na tapet adaptacyjne LASSO oraz technikę knockoffów dla LASSO i regresji grzbietowej.

Symulacja danych i przygotowanie estymatorów β

W pierwszej kolejności wygeneruję macierz planu X, która tym razem ma elementy, które są niezależnymi zmiennymi losowymi z rozkładu $N\left(0, \sigma = \frac{1}{sqrt500}\right)$. Wektory β oraz Y są analogiczne do tych w poprzednim przypadku jedynie ze zmienioną macierzą X. Pozostaje nam zatem jedynie wyznaczyć estymatory β, które wyznaczymy na cztery różne sposoby.

Na początek, skorzystamy z regresji grzbietowej z parametrem wyznaczonym za pomocą walidacji krzyżowej, a następnie różnież LASSO z parametrem wyznaczonym w ten sam sposób. Do wyboru tego parametru posłuży nam funkcja `cv.glmnet`, znajdująca się w bibliotece, o której wspominałam przy wyznaczaniu λ minimalizującego MSE.

Następnie zajmę się adaptacyjnym LASSO. Wagi do niego wybiorę na dwa różne sposoby. W pierwszej kolejności, wagi będą wynosiły $\frac{1}{|\hat{\beta}_i|}$, gdzie $\hat{\beta}_i$ to estymator wyznaczony wcześniej dla regresji grzbietowej. Dzięki tym wagom, wyznaczę nową macierz planu X, którą wyliczę jako przemnożenie wcześniej wyznaczonej macierzy planu X wraz z macierzą diagonalną, gdzie na diagonali znajdują się wartości $\frac{1}{w_j}$, gdzie w_j oznacza odpowiednie wagi. Dopiero dla takiej macierzy korzystamy z funkcji `cv.glmnet` i za jej pomocą wyznaczamy estymatory LASSO parametrów β, które następnie ponownie dzielimy przez wagi.

Drugie adaptacyjne LASSO natomiast będzie miało wagi wybrane w nieco inny sposób. Tym razem, pierwotne estymatory β, będą tymi dla LASSO, wyznaczonymi na początku. Następnie, wyestymuję σ, jako $\hat{\sigma} = \sqrt{\frac{RSS}{n-k}}$ (gdzie RSS liczymy jako sumę kwadratów różnic między prawdziwą wartością Y, a iloczynem X i estymatora β wyznaczonego dla LASSO, a k jest liczbą zmiennych wybranych przez LASSO - zatem liczbą zmiennych niezerowych). Następnie usuwamy zmienne, dla których wyznaczony estymator LASSO dla β jest zerowy, a wagi oznaczamy jako $w_i = \frac{\hat{\sigma}}{|\hat{\beta}_i|}$. Na zmiennych, których nie uzunęliśmy stosujemy

adaptacyjne LASSO z parametrem wygładzającym $\lambda = \hat{\sigma}\Phi^{-1}\left(1 - \frac{0.2}{2p}\right)$, gdzie $p = 500$. Zrobię to stosując funkcję `glmnet`.

Dla tak przygotowanych danych dokonam analizy na początku dla jednokrotnego powtórzenia eksperymentu, a następnie dla wielokrotnego losowania.

Porównanie SE dla różnych estymatorów β

Zajmijmy się zatem porównaniem błędu kwadrtowego dla każdego z tych estymatorów. Poniżej umieszczam tabele dla wyliczonego SE.

Table 7: SE dla pierwszego typu beta

	Ridge	LASSO	AdLASSO1	AdLASSO2
k = 5	76.53229	19.81237	55.51951	22.68282
k = 20	306.20183	139.52514	150.73368	165.24416
k = 100	1514.66011	448.27828	490.53907	511.92983

Table 8: SE dla drugiego typu beta

	Ridge	LASSO	AdLASSO1	AdLASSO2
k = 5	76.64145	37.82401	72.74659	44.74738
k = 20	75.35378	77.84913	119.91794	79.54513
k = 100	75.05747	77.62738	132.52426	80.00000

Jak widać w powyższych tabelach, najmniejsze SE są dla metody LASSO w obu przypadkach β. AdLASSO z drugiego typu wagami dobrze minimalizuje SE dla dużej liczby zer, ale też dla małych wartości prawdziwych (tj. gdy wartości są mniejsze od jedynki, dla największej wartości k w drugim typie β). Wszystkie nie radzą sobie najlepiej z kolei gdy mamy do czynienia z wieloma dużymi wartościami (tj. pierwszy typ β, $k = 100$, gdzie mamy pierwsze 100 współrzędnych równych 4). Tam wartości są bardzo duże, w szczególności dla regresji grzbietowej, gdzie wartość SE wynosi ponad półtora tysiąca. Wynika to prawdopodobnie z tego, że LASSO i oba typy AdLASSO zerują część zmiennych, które (w momencie gdy błędnie wyzerowane) dokładają dość dużo do błędu kwadratowego. Z kolei regresja grzbietowa estymuje wartości parametru, co prowadzi do większych błędów. Dokłada ona błędy zarówno przez niepoprawną estymację parametrów niezerowych, jak i (przede wszystkim) małe, jednak niezerowe wartości w miejscach, gdzie prawdziwe wartości wynoszą zero. Z tego względu błędy dla tego typu wektorów β, gdzie wiele wartości jest różnych od zera i dużo od niego większych widzimy duży wzrost w wartościach SE.

Analiza FDR oraz mocy

Do tej analizy potrzebujemy jeszcze zastosować technikę knockoffów dla LASSO oraz regresji grzbietowej, aby móc również je porównać. Chcemy, aby dzięki procedurze knockoffów kontrolować FDR na poziomie 0.2.

W celu wykonania procedury knockoffów wykonujemy ponowne losowanie macierzy X. Następnie, po sklejeniu nowej macierzy, wraz z oryginalną, liczymy wektor estymatorów dla regresji stworzonej dla zwiększonej macierzy. Ustalamy $w_j = |\hat{\beta}^j| - |\hat{\beta}^{j+p}|$, a następnie liczymy próg

$$\hat{t} = \min\left\{t > 0 : \frac{1 + \#\{j : 1_j \leq -t\}}{\#\{j : w_j \geq t\} \vee 1}\right\}$$

i obcinamy estymator, ustalając zera dla takich wartości j, gdzie $w_j < \hat{t}$. Poniżej przedstawiam tabele dla mocy (wyliczonej jako liczba prawdziwych odkryć podzielona przez liczbę niezerowych wartości parametru)

oraz FDR (wyliczonej jako liczba fałszywych odkryć przez liczbę wszystkich odkryć). Trzeba oczywiście wziąć pod uwagę, że w naszym przypadku badamy jedynie jeden przypadek, zatem może się zdażyć, że dana metoda nie zidentyfikuje żadnej zmiennej i dopiero w przypadku większej liczby powtórzeń zobaczymy bardziej zbliżone do prawdziwych wartości mocy oraz FDR.

Table 9: Moc dla pierwszego typu beta

	LASSO	AdLASSO1	AdLASSO2	Ridge knockoffs	LASSO knockoffs
k = 5	1.00	1.00	1.00	1.00	0
k = 20	0.95	0.95	0.65	0.50	0
k = 100	0.96	0.93	0.83	0.38	0

Table 10: Moc dla drugiego typu beta

	LASSO	AdLASSO1	AdLASSO2	Ridge knockoffs	LASSO knockoffs
k = 5	1.00	1.00	0.8	0	0
k = 20	0.75	0.85	0.2	0	0
k = 100	0.04	0.34	0.0	0	0

Table 11: FDR dla pierwszego typu beta

	LASSO	AdLASSO1	AdLASSO2	Ridge knockoffs	LASSO knockoffs
k = 5	0.8387097	0.9074074	0.0000000	0.0000000	0
k = 20	0.7710843	0.7978723	0.1333333	0.6000000	0
k = 100	0.5675676	0.4561404	0.0777778	0.2962963	0

Table 12: FDR dla drugiego typu beta

	LASSO	AdLASSO1	AdLASSO2	Ridge knockoffs	LASSO knockoffs
k = 5	0.6875000	0.9315068	0.0	0	0
k = 20	0.7727273	0.8023256	0.6	0	0
k = 100	0.4285714	0.6666667	0.0	0	0

Jak widać w powyższych tabelach, dla LASSO z techniką knockoffów mamy do czynienia z sytuacją, w której nie zidentyfikował on żadnych zmiennych. Podobnie dla knockoffów w regresji grzbietowej, gdzie również dla drugiego typu beta żadne zmienne nie zostały zidentyfikowane. Skupmy się zatem bardziej na pierwszych trzech metodach, a knockoffy przeanalizujemy bardziej, gdy spojrzymy na stukrotne powtórzenie eksperymentu. W tym przypadku możemy zobaczyć, że LASSO (podobnie jak widzieliśmy wcześniej) identyfikuje on dość dużo zmiennych, jednak nie wszystkie są zidentyfikowane poprawnie. W pierwszym przypadku beta widzimy, że zarówno LASSO jak i AdLASSO1 radzą sobie bardzo podobnie, jednak gdy spojrzymy na drugi typ beta, widzimy, że (w szczególności dla największego k) pierwszy rodzaj AdLASSO najlepiej identyfikuje zmienne (mimo że wciąż wybiera bardzo dużo zmiennych, które nie są potrzebne). Na koniec, AdLASSO2 bardzo dobrze identyfikuje zmienne, gdy niezerowe wartości β są duże (tj. pierwszy typ β), jednak zupełnie sobie nie radzi w przypadku drugiego typu β i większych wartości k, gdzie nie identyfikuje zmiennch, lub identyfikuje je niezbyt poprawnie.

Analiza powtórzonego eksperymentu

Spójrzmy teraz jak zmieniają się wartości MSE oraz mocy i FDR, gdy zwiększymy liczbę powtórzeń do 100 i uśrednimy wyniki. W pierwszej kolejności przeanalizujmy tabele dla MSE wraz z wykresem pudełkowym, w którym zmieniłam podziałkę na logarytmiczną, w celu dokładniejszej czytelności wykresu.

Table 13: MSE dla pierwszego typu beta

	Ridge	LASSO	AdLASSO1	AdLASSO2
k = 5	76.78057	31.02704	69.31961	29.18981
k = 20	306.66707	106.94549	118.64976	108.46554
k = 100	1523.29767	480.42682	513.54191	550.91344

Table 14: MSE dla drugiego typu beta

	Ridge	LASSO	AdLASSO1	AdLASSO2
k = 5	76.70215	30.74203	69.20616	27.85946
k = 20	76.05430	70.05522	114.93142	73.73809
k = 100	75.97165	82.08956	141.41676	81.16590

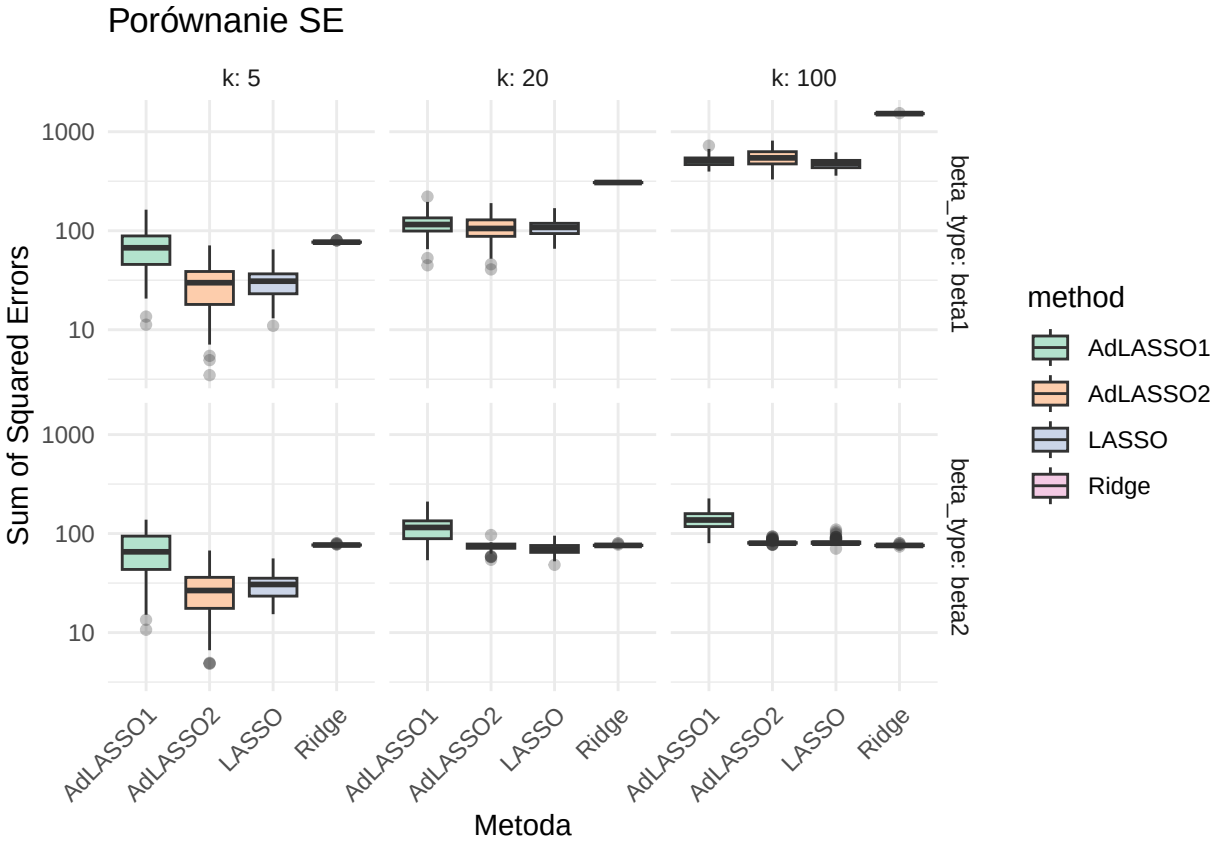

Jak widać w powyższych tabelach, poonownie można zobaczyć, że AdLASSO2 jest porównywalne do metody LASSO. Ponownie, najgorzej radzą one sobie, gdy wartości β są w dużej części niezerowe (pierwszy typ β, $k = 100$).

Patrząc z kolei na wykresy, w celu uzyskania dodatkowej informacji, można również zobaczyć dość duży rozrzut, zarówno dla AdLASSO1, jak i AdLASSO2 przy małej liczbie niezerowych wartości ($k = 5$). Z kolei estymator regresji grzbietowej w każdym przypadku przyjmuje wartości dość mocno do siebie zbliżone. Przy pierwszym typie β możemy zobaczyć, że to AdLASSO2 ma największy rozrzut, z kolei w drugim przypadku z taką sytuacją mamy do czynienia dla AdLASSO1.

Spójrzmy teraz na tabele i wykresy pudełkowe dla mocy oraz FDR.

Table 15: Moc dla pierwszego typu beta

	LASSO	AdLASSO1	AdLASSO2	Ridge knockoffs	LASSO knockoffs
k = 5	0.9580	0.9820	0.8080	0.324	0.3720
k = 20	0.9805	0.9830	0.8380	0.499	0.1610
k = 100	0.9756	0.9167	0.8371	0.246	0.0872

Table 16: Moc dla drugiego typu beta

	LASSO	AdLASSO1	AdLASSO2	Ridge knockoffs	LASSO knockoffs
k = 5	0.9720	0.9900	0.8320	0.3480	0.3900
k = 20	0.3990	0.6795	0.1420	0.0325	0.0505
k = 100	0.0863	0.2989	0.0149	0.0050	0.0071

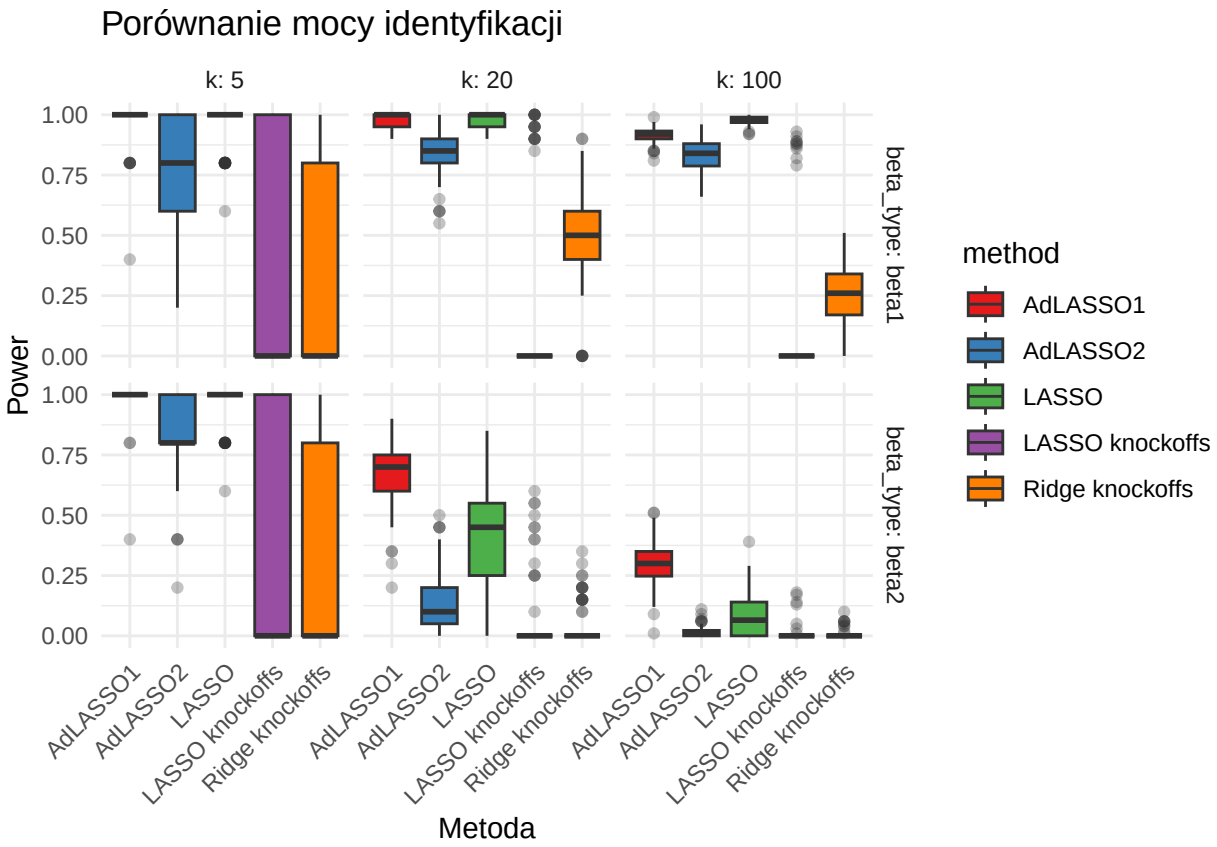

Table 17: FDR dla pierwszego typu beta

	LASSO	AdLASSO1	AdLASSO2	Ridge knockoffs	LASSO knockoffs
k = 5	0.7333036	0.9016010	0.0928135	0.1278317	0.2168586
k = 20	0.7418662	0.7788178	0.1095012	0.1751103	0.0983149
k = 100	0.5929204	0.5055642	0.1166613	0.1648676	0.0416396

Table 18: FDR dla drugiego typu beta

	LASSO	AdLASSO1	AdLASSO2	Ridge knockoffs	LASSO knockoffs
k = 5	0.7402574	0.8818701	0.0946190	0.1297579	0.2518376
k = 20	0.5898685	0.8240752	0.1244450	0.0771242	0.0640368
k = 100	0.4248809	0.6689702	0.1538975	0.0527414	0.0261009

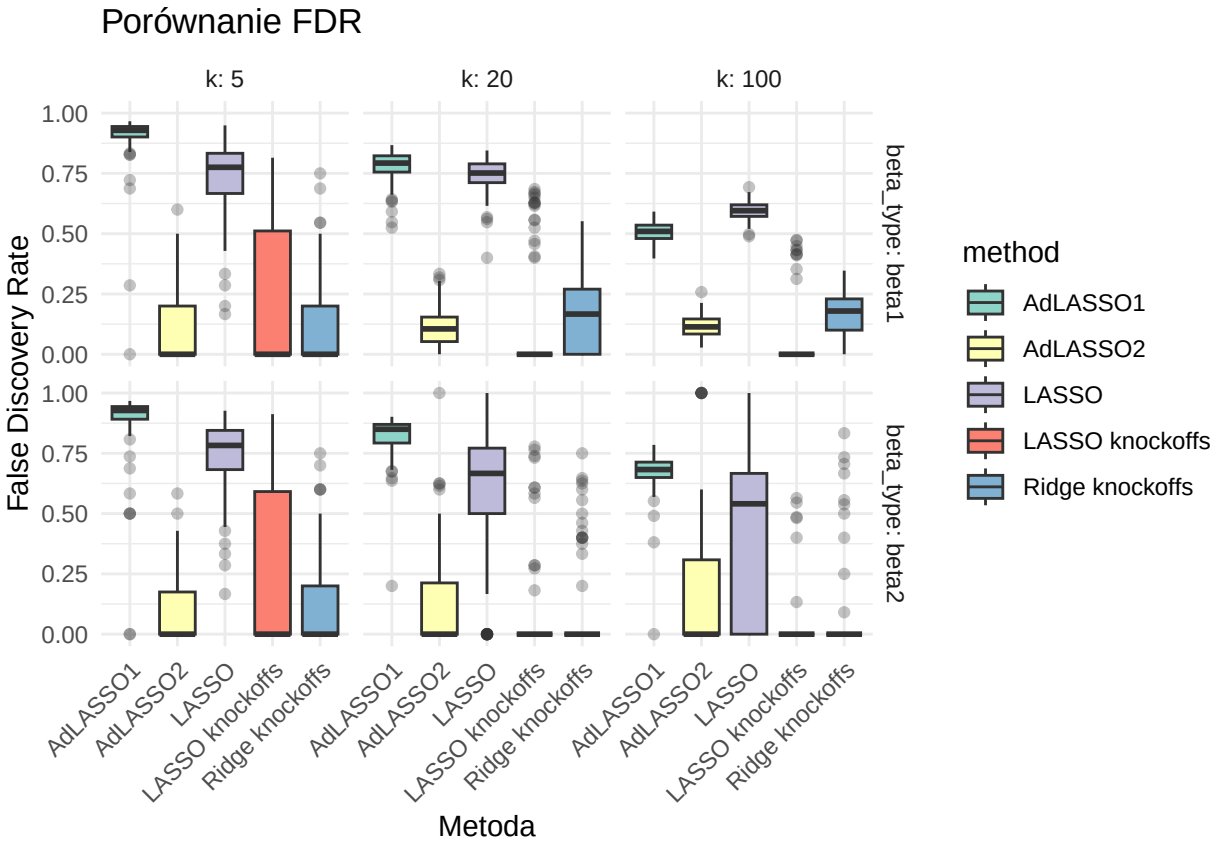

W tym przypakdu zacznijmy od knockoffów, które poprzednio ominęłam. Jak widać, nie ma tutaj zbyt dobrej mocy testu, jednak faktycznie możemy do pewnego stopnia zobaczyć, że FDR jest w większości mniejszy od ustalonego 0.2. Jedynym wyjątkiem jest LASSO z knockoffami dla 5 niezerowych współrzędnych, gdzie FDR wynosi nieco ponad 0.2. Z kolei ponownie możemy zobaczyć problem z identyfikacją jakichkolwiek zmiennych, w szczególności dla dużej liczby niezerowych. Moc, zarówno dla LASSO z knockoffami jak i regresji grzbietowej z knockoffami dla największej wartości k w przypadku drugiego typu β wynosi mniej niż 1. Oznacza to, że mniej niż jedna zmienna jest w tym przypadku poprawnie zidentyfikowana. Wyższy jest procent w przypadku FDR, bo jest to 0.05 oraz 0.02 odpowiedniu dla regresji grzbietowej oraz dla LASSO z knockoffami.

Z kolei patrząc na pozostałe trzy metody, analizowane wstępnie już wcześniej, to możemy zobaczyć, że dla pierwszego typu β zdecydowanie najlepiej radzi sobie AdLASSO2, w którym możemy zauważyć zarówno wysoką moc identyfikacji zmiennych, jak i niskie FDR. Zarówno dla AdLASSO1, jak i AdLASSO2 możemy spostrzec, że radzą sobie podobnie dobrze - zarówno identyfikując zmienne poprawnie, jak i dając nam dodatkowo wiele fałszywych odkryć. Niestety, wciąż żadne z nich nie radzi sobie najlepiej, gdy prawdziwe wartości β się zmniejszają. Dla AdLASSO1 dostajemy bardzo wysokie FDR, przy jednoczesnej dość małej mocy (choć jest ona najwyższa ze wszystkich, zarówno dla $k = 20$, jak i $k = 100$ przy drugim typie β). Podobnie jest dla LASSO, gdzie zarówno moc, jak i FDR są nieco niższe. Z kolei AdLASSO2 ma zarówno najniższą moc, jak i najniższe FDR, co sprawia, że stosunkowo niewiele zmiennych identyfikuje w sytuacji

mniejszych wartości prawdziwego β.

Spójrzmy teraz na wykresy, w pierwszej kolejności skupiając się na mocy. Pierwszą rzucającą się w oczy rzeczą jest fakt, że dla knockoffów mamy do czynienia z rozrzutem wartości po całej osi y dla najmniejszej wartości k. Oznacza to, że mieliśmy do czynienia zarówno z sytuacjami, w których zidentyfikowane zostały zarówno wszystkie zmienne, jak i żadna. Również AdLASSO2 ma dość duży rozrzut dla najmniejszego k. W pierwszym typie β można również zobaczyć, że (poza knockoffami) wartości mocy są dość duże, w przeciwieństwie do drugiego typu β, gdzie można zobaczyć jak moc maleje wraz ze wzrostem niezerowych wartości. Dla LASSO z knockoffami można zobaczyć, że w przypadku pierwszego typu β wartości są w głównej mierze zerowe, jednak występują pojedyncze wartości odstające, które są dużo większe - równe 1 lub bardzo tej jedynki bliskie. Z kolei regresja grzbietowa z knockoffami ma wartości mocy rozrzucone w zupełnie inny sposób, gdyż przede wszystkim są one po środku osi (dla $k = 20$) oraz poniżej 0.5 (dla $k = 100$). Z kolei dla drugiego typu β i większych wartości k oba knockoffy radzą sobie podobnie i w większości znajdują się w okolicach zera.

Przyglądając się teraz FDR, można zobaczyć duży rozrzut LASSO z knockoffami dla $k = 5$, jednak w każdym przypadku występują wartości odstające po całej długości osi. Tym razem jednak możemy również zauważyć, że FDR dla drugiego typu β oraz estymatora LASSO również ma duży rozrzut - po całej osi. Tym razem nie widać konkretnej struktury ułożenia wykresów pudełkowych. Dla AdLASSO1 FDR jest stosunkowo duże (z jednym wyjątkiem dla pierwszego typu β i $k = 100$), natomiast widać również małe wartości odstające, w tym 0. Największe watości przyjmuje często również estymator LASSO. Z kolei knockoffy i AdLASSO2 mają stosunkowo małe wartości (chociaż w drugim typie wektora β dla $k = 20$ oraz $k = 100$ widać dość dużo wartości odstających).

Analiza dla macierzy planu z zależnymi zmiennymi

Tym razem zajmiemy się ostatnim typem danych, gdzie macierz X pochodzi z rozkładu normalnego, jednak tym razem ma ona rozkład $X_i \sim N(0, \frac{1}{n}\Sigma$, gdzie $\Sigma_{ii} = 1$ oraz $\Sigma_{ij} = 0.5$. Porównywane będą te same wartości, co w poprzednim zadaniu, zatem nie będę ponownie wyjaśniać, w jaki sposób je przygotowuję. Warto jedynie wyjaśnić, że macierz X przygotowuję, generując ją za pomocą funkcji `rmvnorm` służącej do generowania elementów z wielowymiarowego rozkładu normalnego. Jedyną różnicą, będzie przygotowanie macierzy do knockoffów, w której generuję ją z rozkładu warunkowego $\tilde{X}_{(i)}|X_{(i)} \sim N(\mu, V)$, gdzie $\mu = X_{(i)} - X_{(i)}\Sigma^{-1}\text{diag(s)}$ oraz $V = 2\text{diag(s)} - \text{diag(s)}\Sigma^{-1}\text{diag(s)}$, natomiast $\text{diag(s)} = siag(2\lambda_{\min}(\Sigma) \wedge 1)$. Liczę zatem w pierwszej kolejności najmniejszą wartość własną macierzy Σ, będącej macierzą kowariancji dla wektorów w macierzy X. Następnie wyznaczam każdy wektor macierzy $\tilde{X}$ losując z rozkładu normalnego wielowymiarowego o parametrach jak opisanych wyżej.

Analiza SE

Poniżej przedstawiam wartości SE dla tego typu danych.

Table 19: SE dla pierwszego typu beta

	Ridge	LASSO	AdLASSO1	AdLASSO2
k = 5	78.37467	42.00684	28.59911	25.51626
k = 20	306.19410	137.39090	132.24371	201.72034
k = 100	1307.10800	623.60741	664.53690	1114.76518

Przyglądając się tym wartościom można zauważyć znaczne pogorszenie się AdLASSO2 dla pierwszego typu β. Wartości dla najmniejszej liczby niezerowych zmiennych są dość podobne do pozostałych, jednak dla $k = 100$ możemy zobaczyć, że wynosi ona niemal tyle, co ta dla regresji grzbietowej, która dotychczas miała prawie największe wartości (zaraz po regresji grzbietowej). Tym razem to ona ma jedne z lepszych

Table 20: SE dla drugiego typu beta

	Ridge	LASSO	AdLASSO1	AdLASSO2
k = 5	78.42503	59.74040	62.96106	71.48629
k = 20	76.25169	85.34669	94.71326	184.96402
k = 100	65.24443	149.57636	145.35430	329.09904

wyników. Szerszą analizę będę mogła jednak zrobić, patrząc na tabele z MSE oraz wykresy pudełkowe z SE w późniejszej części raportu.

Analiza FDR oraz mocy

Spójrzmy teraz na tabele dla FDR oraz mocy.

Table 21: Moc dla pierwszego typu beta

	LASSO	AdLASSO1	AdLASSO2	Ridge knockoffs	LASSO knockoffs
k = 5	0.80	0.80	0.80	1	0.80
k = 20	1.00	0.95	0.75	1	1.00
k = 100	0.93	0.92	0.74	1	0.93

Table 22: Moc dla drugiego typu beta

	LASSO	AdLASSO1	AdLASSO2	Ridge knockoffs	LASSO knockoffs
k = 5	0.80	0.80	0.60	1	0.80
k = 20	0.60	0.50	0.25	1	0.60
k = 100	0.37	0.39	0.17	1	0.37

Table 23: FDR dla pierwszego typu beta

	LASSO	AdLASSO1	AdLASSO2	Ridge knockoffs	LASSO knockoffs
k = 5	0.8620690	0.7142857	0.4285714	0.9898167	0.8518519
k = 20	0.7333333	0.6415094	0.3478261	0.9600000	0.7333333
k = 100	0.5255102	0.4523810	0.2127660	0.8000000	0.5255102

Table 24: FDR dla drugiego typu beta

	LASSO	AdLASSO1	AdLASSO2	Ridge knockoffs	LASSO knockoffs
k = 5	0.7777778	0.6000000	0.5000000	0.989648	0.7777778
k = 20	0.7500000	0.6666667	0.5454545	0.960000	0.7446809
k = 100	0.6372549	0.6020408	0.5405405	0.800000	0.6372549

W tym przypadku nie możemy zobaczyć poprzedniego problemu z brakiem identyfikacji zmiennych przy knockoffach. Tutaj regresja grzbietowa z knockoffami dobrze zidentyfikowała wszystkie niezerowe wartości β, jednak nie widać tutaj również żadnej kontroli FDR, które w tym przypadku jest najwyższe. Knockoffy dla LASSO również zdają się nie kontrolować FDR w żądanym przez nas stopniu (0.2), jednak jest ono niższe niż w przypadku regresji grzbietowej. Najniższe FDR w prawie każdym przypadku (poza największą liczbą niezerowych zmiennych w drugim typie β) jest dla AdLASSO2, gdzie prawie wszędzie wynosi ono mniej niż 0.5. Z kolei AdLASSO1 oraz LASSO wskazuje na wcześniej już zauważone problemy.

Analiza powtórzonego eksperymentu

Spójrzmy teraz jak zmieniają się wartości gdy powtórzymy eksperyment stukrotnie. Najpierw przyjrzyjmy się tabeli z wartościami MSE a także wykresowi pudełkowemu dla 100 wyliczonych wartości SE.

Table 25: MSE dla pierwszego typu beta

	Ridge	LASSO	AdLASSO1	AdLASSO2
k = 5	78.40205	49.0877	42.76851	54.97496
k = 20	306.63544	155.5987	149.09050	205.96158
k = 100	1309.55718	636.2039	632.60959	1100.88236

Table 26: MSE dla drugiego typu beta

	Ridge	LASSO	AdLASSO1	AdLASSO2
k = 5	78.39578	50.10836	42.05500	53.63851
k = 20	76.52264	89.74552	91.21408	159.25241
k = 100	65.29418	150.21844	153.68431	344.64081

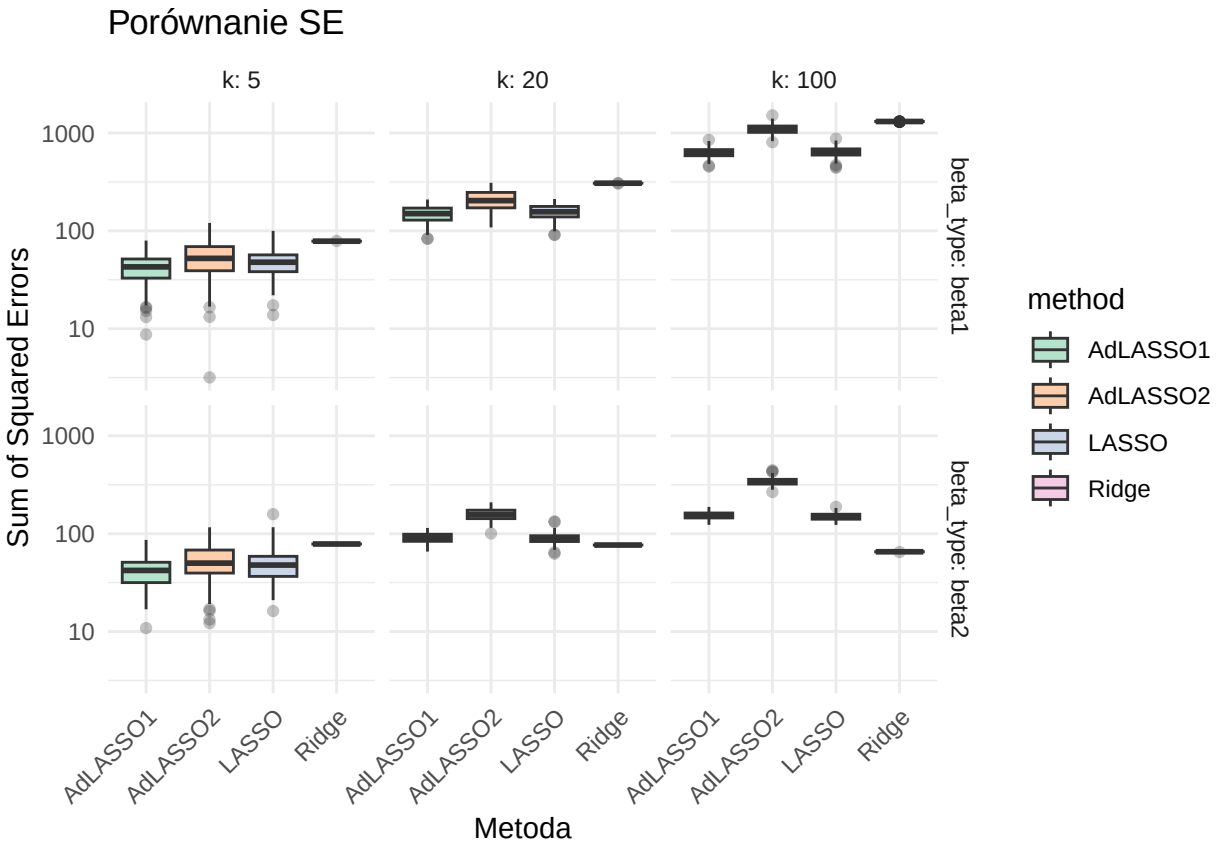

W tabeli ponownie można zobaczyć, że wartość MSE dla AdLASSO2 jest dużo większe niż poprzednio. W przypadku drugiego typu β ponownie możemy zauważyć, że dla regresji grzbietowej wszystkie wartości są do siebie podobne, a dla $k = 20$ oraz $k = 100$ najlepsze ze wszystkich. W pozostałych przypadkach najmniejsze wartości są te wyliczone dla AdLASSO1.

Z kolei patrząc na wykres pudełkowy, ponownie można zobaczyć dość duży rozrzut wartości dla $k = 5$ dla wszystkich estymatorów, poza regresją grzbietową (która dla każdej liczby niezerowych zmiennych, a także

bez względu na β ma bardzo mały rozrzut). W pozostałych przypadkach wartości zachowują się podobnie - rosną znacznie dla pierwszego typu β przy wzroście niezerowych zmienncyh i rosną nieco mniej (z czego najbardziej AdLASSO2) dla drugiego typu β.

Spójrzmy teraz na uśrednioną moc oraz FDR a także na wykresy pudełkowe tych wartości.

Table 27: Moc dla pierwszego typu beta

	LASSO	AdLASSO1	AdLASSO2	Ridge knockoffs	LASSO knockoffs
k = 5	0.8960	0.8560	0.666	1	0.8960
k = 20	0.9245	0.9125	0.718	1	0.9235
k = 100	0.9427	0.9354	0.726	1	0.9426

Table 28: Moc dla drugiego typu beta

	LASSO	AdLASSO1	AdLASSO2	Ridge knockoffs	LASSO knockoffs
k = 5	0.8960	0.8620	0.6560	1	0.8960
k = 20	0.4930	0.4455	0.2320	1	0.4925
k = 100	0.3516	0.3404	0.1317	1	0.3484

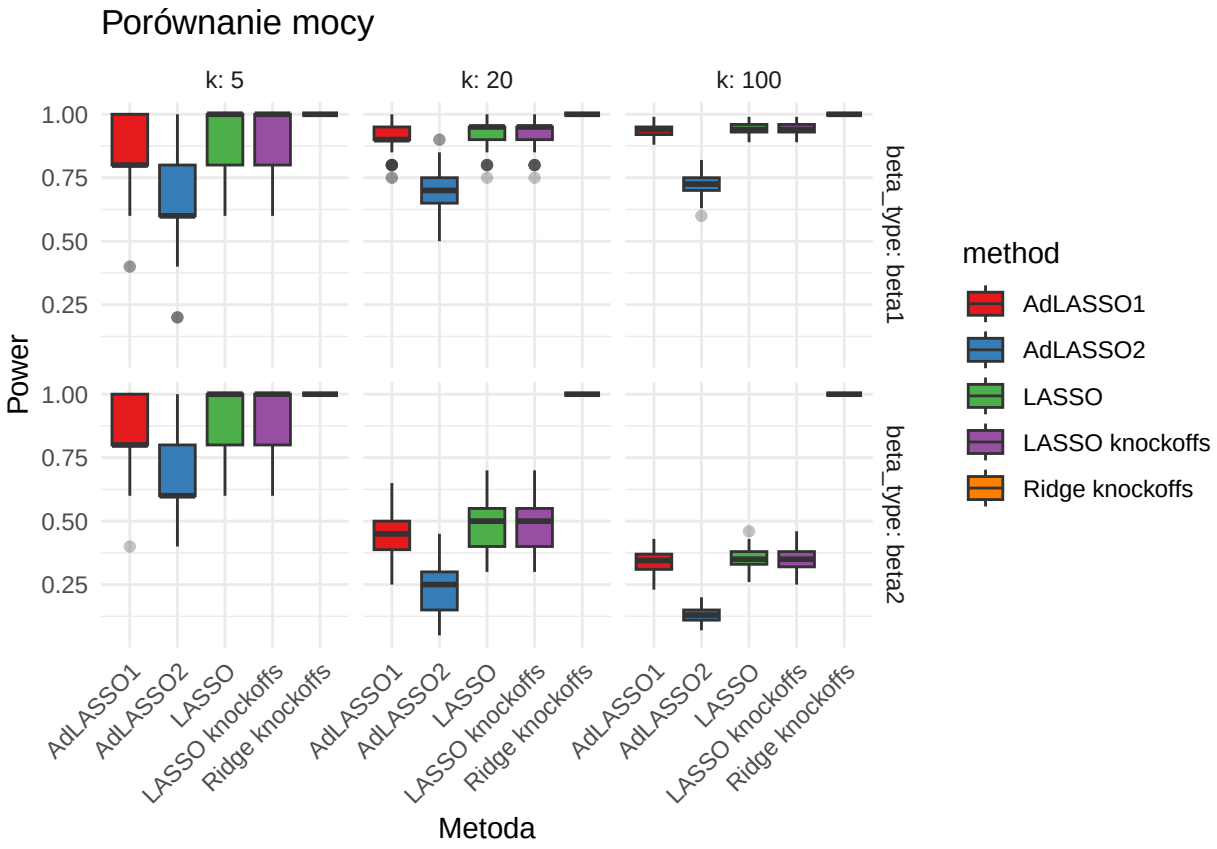

Table 29: FDR dla pierwszego typu beta

	LASSO	AdLASSO1	AdLASSO2	Ridge knockoffs	LASSO knockoffs
k = 5	0.8263271	0.6920138	0.4408651	0.9898236	0.8248520
k = 20	0.7370747	0.6833666	0.3817344	0.9600000	0.7352341
k = 100	0.5146937	0.4801467	0.2403621	0.8000000	0.5145475

Table 30: FDR dla drugiego typu beta

	LASSO	AdLASSO1	AdLASSO2	Ridge knockoffs	LASSO knockoffs
k = 5	0.8292641	0.6937869	0.4357608	0.9898092	0.8279686
k = 20	0.8156885	0.7702554	0.6608970	0.9600000	0.8145521
k = 100	0.6570676	0.6159287	0.5771051	0.8000000	0.6571307

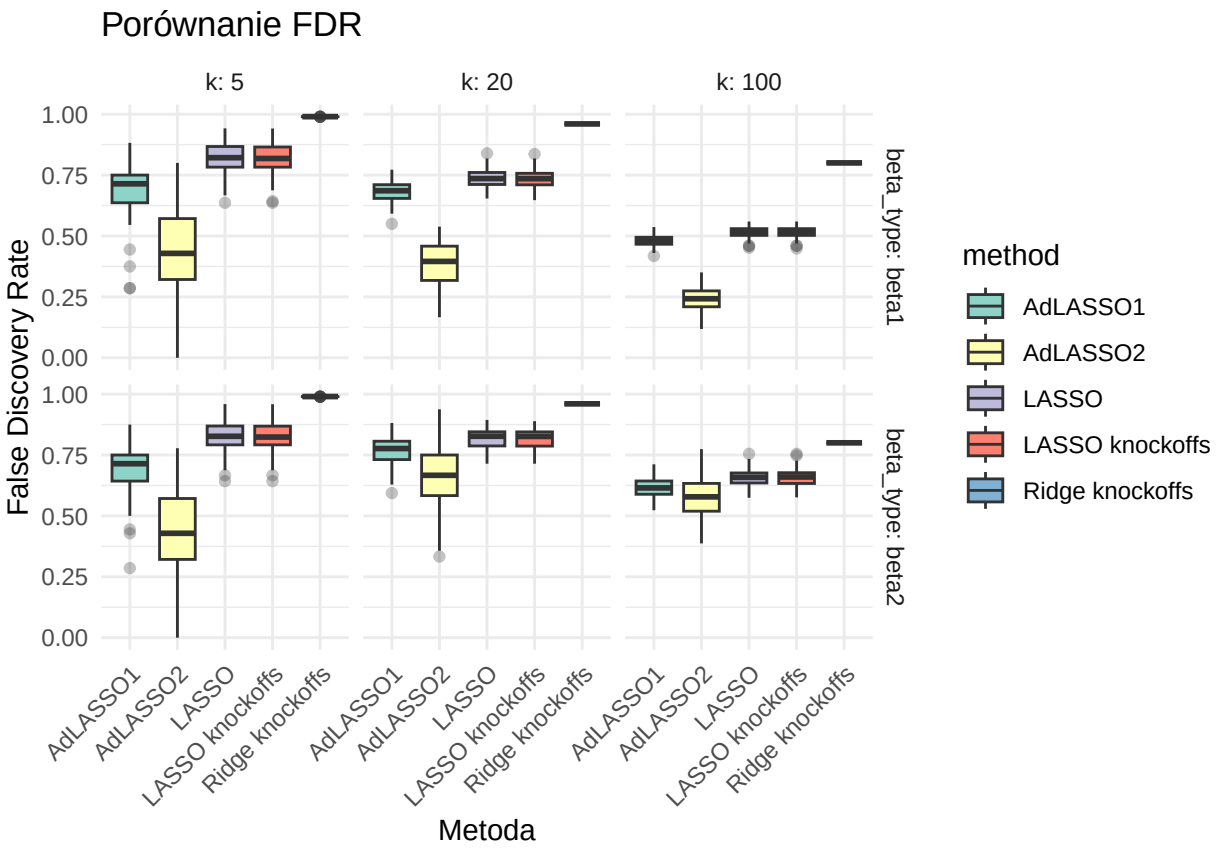

W przypadku mocy, gdy mamy do czynienia ze zmiennymi zależnymi możemy zobaczyć znaczną poprawę, szczególnie dla knockoffów z regresją grzbietową, dla których moc z każdym z przypadków wynosi 1. Z kolei w pozostałych przypadkach również możemy zobaczyć wzrost i stosunkowo duże wartości. W przypadku drugiego typu β ponownie (poza regresją grzbietową) możemy zobaczyć dość niskie wartości dla $k = 20$ oraz $k = 100$. Wyniki są podobne dla tych z niezależnymi wartościami w macierzy X, jednak można zauważyć nieco wyższe wyniki tym razem, w szczególności dla $k = 100$ w przypadku drugiego typu wektora β.

Patrząc na wykresy pudełkowe, widać, że rozrzut wartości jest tym razem dużo mniejszy, jednak rozkładają się w dość podobny sposób.

W przypadku gdy patrzymy na FDR główną rzeczą, która rzuca nam się w oczy jest brak kontroli FDR dla knockoffów. FDR wynosi w przypadku regresji grzbietowej ponad 0.8 i ponad 0.5 w przypadku LASSO.

Z kolei dla pozostałych przypadków widzimy podobne wartości (LASSO lub AdLASSO1) lub większe (AdLASSO2).

Patrząc na wykresy pudełkowe możemy widzieć wzrost wartości AdLASSO2 w stosunku do macierzy X o wyrazach będących niezależnymi zmiennymi losowymi. Dla LASSO również można zobaczyć zmniejszony rozrzut w stosunku do poprzenich wykresów. Z kolei LASSO i regresja grzbietowa z knockoffami mają dużo większe i bliższe sobie wartości niż wcześniej. Widać również większe ustrukturyzowanie danych.

Podsumowanie

W przypadku tego eksperymentu mogliśmy zobaczyć wady i zalety każdej z poznanych metod regulacyjnych. Estymator regresji grzbietowej ma dość duże MSE przy dużej liczbie istotnych zmiennych (w porównaniu do pozostałych), jednak jednocześnie dość dobrze sobie radzi, gdy wartości β są stosunkowo niewielkie (nawet gdy niezerowe) w minimalizowaniu MSE. Nie identyfikuje on jednak zmiennych nieistotnych, więc nie jest najlepszym wyborem, gdy na tym nam zależy. Z kolei estymator LASSO identyfikuje zmienne, jednak często niepoprawnie. Jego identyfikacja pogarsza się również w przypadku, gdy mamy do czynienia ze zmiennymi zależnymi. Z kolei adaptacyjne LASSO, jak mogliśmy zobaczyć, możemy dostosowywać do otrzymanych danych. Pierwsze z nich lepiej sobie radzi z danymi niezależnymi, z kolei drugie z takimi, gdzie macierz kowariancji ma niezerowe wartości również poza przekątną. Z kolei knockoffy działają nieco gorzej, gdy mamy do czynienia z macierzą, której elementy na wektorach są zmiennymi zależnymi. Jednocześnie trzeba mieć świadomość, że knockoffy są również bardziej wymagające.

Zatem w zależności od potrzeby, każdy ze sposobów może działać w dobry sposób. Regresja grzbietowa dobrze minimalizuje MSE, w przypadku, gdy mamy dużo niezerowych wartości, które są niewielkie. LASSO jest dobre, gdy chcemy dokonać wstępnej selekcji zmiennych, jednak dla większej precyzji - dobrze będzie skorzystać z adaptacyjnego LASSO (jednak trzeba pamiętać o dobrym doborze wag). Z kolei knockoffy są dobrym wyborem, gdy zależy nam na kontroli FDR, z zastrzeżeniem, że dla macierzy o elementach, które nie są niezależne, może nie występować ta kontrola, jak i również przy pojedynczym powtórzeniu możemy nie widzieć kontroli FDR, gdyż metoda może nie identyfikować żadnej ze zmiennych.