Lista 4.

Amelia Olejniczak

Contents

1 Wprowadzenie **2**

2 Zadanie 1. **2**

2.1 Analiza dla estymatora $\hat{\beta}$ 3

2.2 Analiza dla estymatora $\hat{\Sigma}$ 4

3 Zadanie 2. **4**

3.1 Estymator $\hat{\beta}$ 4

3.2 Estymator $\hat{\Sigma}$ 5

4 Zadanie 3. **5**

4.1 Estymator $\hat{\beta}$ 6

4.2 Estymator $\hat{\Sigma}$ 6

5 Zadanie 4. **7**

5.1 Estymator $\hat{\beta}$ 7

5.2 Estymator $\hat{\Sigma}$ 8

6 Zadanie 5. **8**

6.1 Estymator $\hat{\beta}$ 9

6.2 Estymator $\hat{\Sigma}$ 10

7 Zadanie 6. **10**

7.1 Estymator $\hat{\beta}$ 10

7.2 Estymator $\hat{\Sigma}$ 11

8 Podsumowanie **12**

1 Wprowadzenie

Poniższy raport dotyczy analizy właściwości ogólnych modeli liniowych. Będziemy badać różne przypadki, związane z liczbą obiektów (n), liczbą pomiarów dla każdego obiekru (k) oraz liczbą kolumn w macierzy planu (p), a także, jak na wyniki wpływa sposób estymacji macierzy kowariancji Σ (a zatem macierzy kowariancji między obserwacjami dla jednego obiektu).

Symulację danych zaczniemy od wygenerowania macierzy $X \in \mathbb{M}_{N\times p-1}$ o elementach niezależnych z rozkładu $N\left(0, \sigma = \frac{1}{\sqrt{N}}\right)$, gdzie $N = n * k$. Następnie podzielimy macierz X na $n = \frac{N}{k}$ podmacierzy $X_1, ..., X_n \in \mathbb{M}_{k\times p-1}$ w taki sposób, że X_1 zawiera pierwszych k wierszy z macierzy X, X_2 zawiera kolejnych k wierszy i tak dalej, aż do podmacierzy X_n zawierającej ostatnie k wierszy z macierzy X. Następnie generujemy n niezależnych wektorów losowych

$$y_i = (y_{i1}, ..., y_{ik})' \sim N(X_i\beta, \Sigma) \in \mathbb{R}^k \quad i = 1, 2, ..., n$$

gdzie $\beta = (3, 3, 0)' \in \mathbb{R}^{p-1}$ oraz

$$\Sigma = \gamma^2 \begin{pmatrix} 1 & \rho & \cdots & \rho \\ \rho & 1 \cdots & \rho & \\ \vdots & \vdots & \ddots & \vdots \\ \rho & \rho & \cdots & 1 \end{pmatrix} \in \mathbb{M}_{k\times k}$$

gdzie $\rho = 0.3$ oraz $\gamma = 2$.

Następnie wykonamy 500 powtórzeń eksperymentu i przeanalizujemy własności estymatorów $\hat{\beta}$, $\hat{\gamma}$, $\hat{\rho}$.

2 Zadanie 1.

Pierwsza analiza dotyczyć będzie sytuacji, gdzie $n = 20$, $k = 3$ oraz $p = 4$, a estymator macierzy kowariancji $\hat{\Sigma}$ konstuujemy przy pomocy metody "REML". Dane, generowane jak opisaliśmy wyżej, przedstawimy w jednowymiarowej reprezentacji danych. W pierwszej kolumnie utworzonej ramki danych umieścimy dane obserwacje, w drugiej numer obiektu, w trzeciej moment pomiaru, a na koniec - macierz powiązana z danym obiektem. Ze względu na wykorzystanie ogólnych modelów liniowych to zakładamy, że dane są kompletne i pomiary wykonywane były w tych samych momentach. Poniżej przedstawiam pierwsze kilka wierszy ramki danych, przechowującej nasze informacje.

Table 1: Jednowymiarowa reprezentacja danych

y	id	t	x
-0.1109	1	1	-0.1387 0.0183 0.0756
-0.3203	1	2	-0.2074 -0.1053 0.0956
2.6501	1	3	0.1342 0.0514 -0.0926
-5.6003	2	1	-0.1617 0.1019 0.0005
-0.7883	2	2	0.1290 0.2007 -0.0302
-2.0004	2	3	0.1683 -0.0770 -0.0723
0.3766	3	1	-0.0871 -0.2154 0.0702
-0.5814	3	2	0.0991 -0.0004 0.1774
1.6841	3	3	0.1309 -0.2095 -0.1804

Do wyznaczenia modelu wykorzystamy funkcję `gls` z biblioteki `nlme` ze strukturą kowatiancji:

$$correlation = \textbf{corCompSymm}(form = \sim 1|id)$$
$$weights = varIdent(form = \sim 1)$$

2.1 Analiza dla estymatora $\hat{\beta}$

Następnie wyznaczymy estymator $\hat{\beta}$ poszerzony o intercept. Możemy go policzyć ze wzoru

$$\hat{\beta} = \left(\sum_{i=1}^{n} X_i' \hat{\Sigma}^{-1} X_i \right)^{-1} \left(\sum_{i=1}^{n} X_i' \hat{\Sigma}^{-1} y_i \right)$$

gdzie do każdej podmacierzy X_i dodamy jeszcze kolumnę z jedynkami, aby poprawnie dodać do niej potrzebny intercept. Elementem brakującym do poprawnego wyznaczenia estymatora $\hat{\beta}$ jest estymator $\hat{\Sigma}$, który na szczęście możemy wyczytać, korzystając z funkcji `getVarCov()` i wykonując ją na wcześniej wyznaczonym modelu. Estymator $\hat{\beta}$ ma asymptotyczny rozkład:

$$\hat{\beta} \xrightarrow{d} N \left(\beta, \left(\sum_{i=1}^{n} X_i' \Sigma^{-1} X_i \right)^{-1} \right)$$

Zatem potrzebujemy również wyznaczyć macierz kowariancji dla estymatora $\hat{\beta}$. Jej wartość estymowaną możemy wyznaczyć na dwa sposoby. Pierwszym z nich będzie wyznaczenie jej ze wzoru podanego wyżej (oczywiście zamieniając prawdziwą wartość macierzy kowariancji Σ na jej estymator). Natomiast drugim sposobem na uzyskanie żądanej macierzy jest skorzystanie z funkcji `vcov()`. Poniżej w tabelach umieszczam wyniki odpowiednich wyliczeń, gdzie każdy element macierzy jest przybliżony do 4 miejsca po przecinku.

Table 2: Macierz kowariancji - wzór

0.1296	0.0502	-0.0486	-0.0253
0.0502	3.6030	-0.3915	0.7451
-0.0486	-0.3915	3.2526	0.4121
-0.0253	0.7451	0.4121	6.3364

Table 3: Macierz kowariancji - funkcja vcov()

0.1296	0.0502	-0.0486	-0.0253
0.0502	3.6030	-0.3915	0.7451
-0.0486	-0.3915	3.2526	0.4121
-0.0253	0.7451	0.4121	6.3364

Jak widać powyżej wartości w odpowiadających miejscach macierzy są takie same dla określonej przez nas dokładności przybliżenia. Określając dokładną wartość maksymalnej różnicy między współrzędnymi macierzy otrzymujemy $8.8817842 \times 10^{-16}$, co jest wartością pomijalną, związaną z pewnymi przybliżeniami w obliczeniach dokonywanych przez R.

Spójrzmy teraz na wartości estymatora wektora β. W tabeli poniżej możemy zobaczyć wartość odpowiedniego estymatora $\hat{\beta}$ oraz prawdziwą wartość odpowiednich współrzędnych wektora β. Poniżej zapiszę normę supremum tych wartości. Ponownie, chcemy aby wektor β był rozszerzony o intercept, zatem dodajemy wartość 0 na początku wektora, aby to reprezentował.

Prawdziwe	Estymator
0	-0.5375
3	4.2355
3	2.8892
0	0.9041

Patrząc na tabelę można zobaczyć, że różnice między prawdziwymi wartościami, a estymatorami jest stosunkowo duża. Norma supremum tej różnicy wynosi 1.2355171, zatem faktycznie jest to dość duża różnica,

jednak związana z wariancją widoczną w macierzy kowariancji. Dokładniejsze wyliczenia zobaczymy dla powtórzenia eksperymentu 500 razy,

2.2 Analiza dla estymatora $\hat{\Sigma}$

Pozostaje nam teraz jedynie przeanalizować wartości dla estymacji macierzy Σ. Poniżej przedstawiam wyliczony wcześniej estymator:

4.7142	1.4889	1.4889
1.4889	4.7142	1.4889
1.4889	1.4889	4.7142

Na tej podstawie możemy wyznaczyć estymowane wartości $\hat{\rho}$ oraz $\hat{\gamma}$. Na przekątnej powyższej macierzy mamy wartości $\hat{\gamma}^2$, zatem $\hat{\gamma} = 2.1712$ (różnica - 0.1712). Z kolei aby wyznaczyć drugi z estymatorów musimy podzielić wartość poza przekątną przez kwadrat wskazanego wcześniej estymatora. Zatem $\hat{\rho} = 0.3158$ (różnica - 0.0158). Wiedząc, że wartości prawdziwe każdego z tych estymatorów wynoszą $\gamma = 2$ oraz $\rho = 0.3$ możemy stwierdzić, że różnice nie są stosunkowo duże.

3 Zadanie 2.

Aby odpowiednio przyjrzeć się jednak własnościom danych estymatorów, powtórzę wyznaczanie powyższych własności 500 razy dla 500 różnych wartości zmiennej zależnej y.

3.1 Estymator $\hat{\beta}$

Na podstawie wyznaczonych estymatorów, w pierwszej kolejności, umieszczę histogramy dla $\hat{\beta}_0$ (którego prawdziwa wartość wynosi 0) oraz $\hat{\beta}_1$, (którego prawdziwa wartość wynosi 3). Na nie naniosę asymptotyczne gęstości tych estymatorów (rozkład asymptotyczny podany został wcześniej). Poniżej możemy zobaczyć gotowe histogramy.

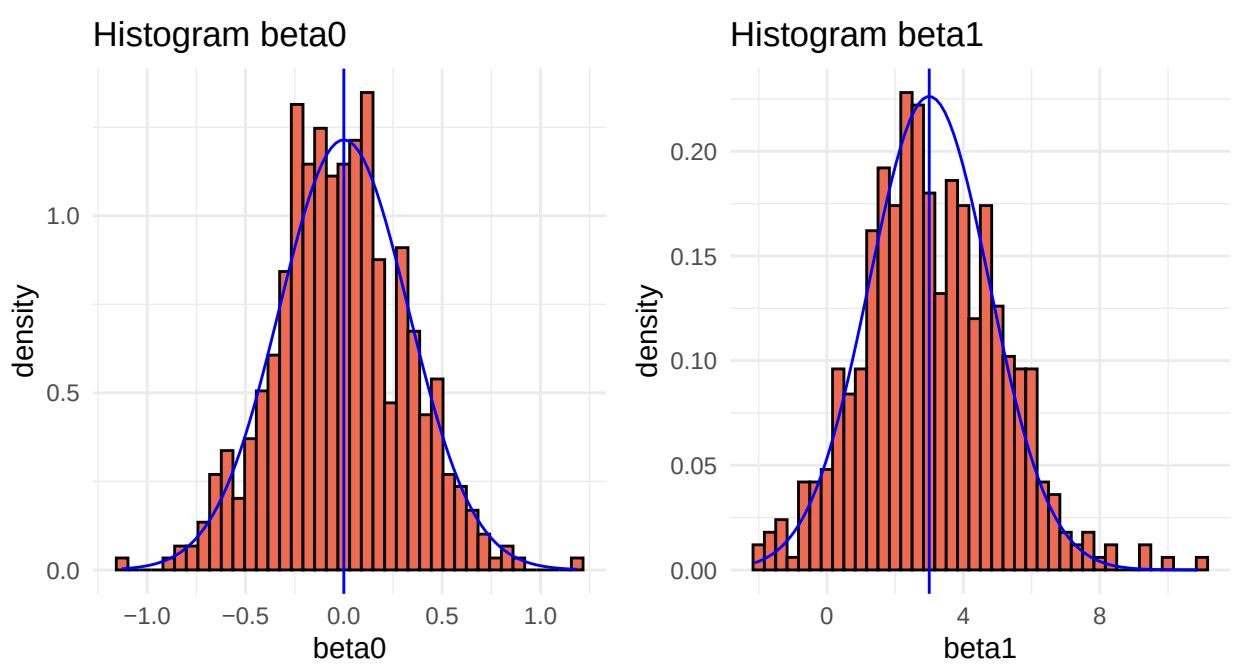

Jak widać, histogramy estymatorów, zarówno β_0, jak i β_1 układają się bardzo podobnie do asymptotycznego rozkładu estymatora $\hat{\beta}$. Pionowa linia wskazuje na wartość oczekiwaną odpowiednich estymatorów i jak widać, jest ona bardzo zbliżona do najwyższych słupków histogramów.

Zabierzmy się teraz za wyznaczenie średniego obciążenia odpowiednich estymatorów wektora β oraz normę supremum tego estymatora. Poniżej możemy zobaczyć wartości obciążeń w tabeli.

Table 4: Wartości obciążenia dla beta

beta0_bias	beta1_bias	beta2_bias	beta3_bias
-0.0147	0.0913	-0.154	-0.0078

Jak widać powyżej, wartości w tabeli są bardzo niewielkie, co wiąże się z tym, że według teorii estymator jest nieobciążony. Z kolei norma supremum wynosi 10.8726. Zgadza się to z powyższymi wykresami, gdzie widzimy, że w przpadku $\hat{\beta}_1$ najdalsze wartości są dość daleko od średnich. Warto zauważyć, że wartości $\hat{\beta}_0$ są dużo bardziej do siebie zbliżone, w porównaniu do $\hat{\beta}_1$.

3.2 Estymator $\hat{\Sigma}$

Na koniec tej części zajmijmy się ponownie estymatorami $\hat{\rho}$ i $\hat{\gamma}$, które wiążą się bezpośrednio z estymowaną wartości macierzy kowariancji. Poniżej przedstawiam dwa histogramy z wartościami estymatorów, na których widać również pionową linię wyznaczającą prawdziwą wartość tych wielkości.

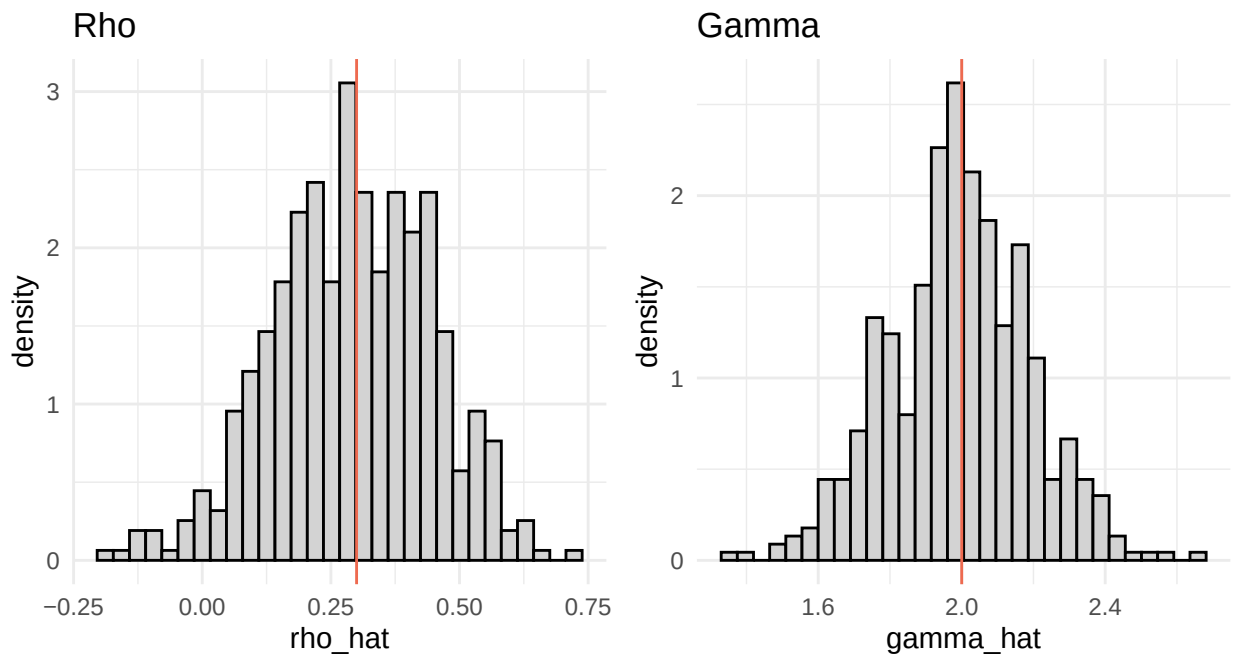

Powyższe histogramy są ułożone w dzwon przypominający krzywą Gaussa, zatem jest pewna szansa, że te zmienne mają rozkład normalny. Jeśli chodzi o średnie obciążenie, to dla $\hat{\rho}$ wynosi ono -0.0086, natomiast dla $\hat{\gamma}$ jest to -0.0072. Wartości, podobnie jak dla β są bardzo niewielkie, zatem (z pewnym błędem) można stwierdzić, że te estymatory są nieobciążone.

4 Zadanie 3.

Spójrzmy teraz, jak powyższe własności się zmieniają, gdy zmienimy liczbę obiektów z $n = 20$, na $n = 500$.

4.1 Estymator $\hat{\beta}$

Ponownie zacznijmy od przyjrzenia się histogramom dla $\hat{\beta}_0$ oraz $\hat{\beta}_1$.

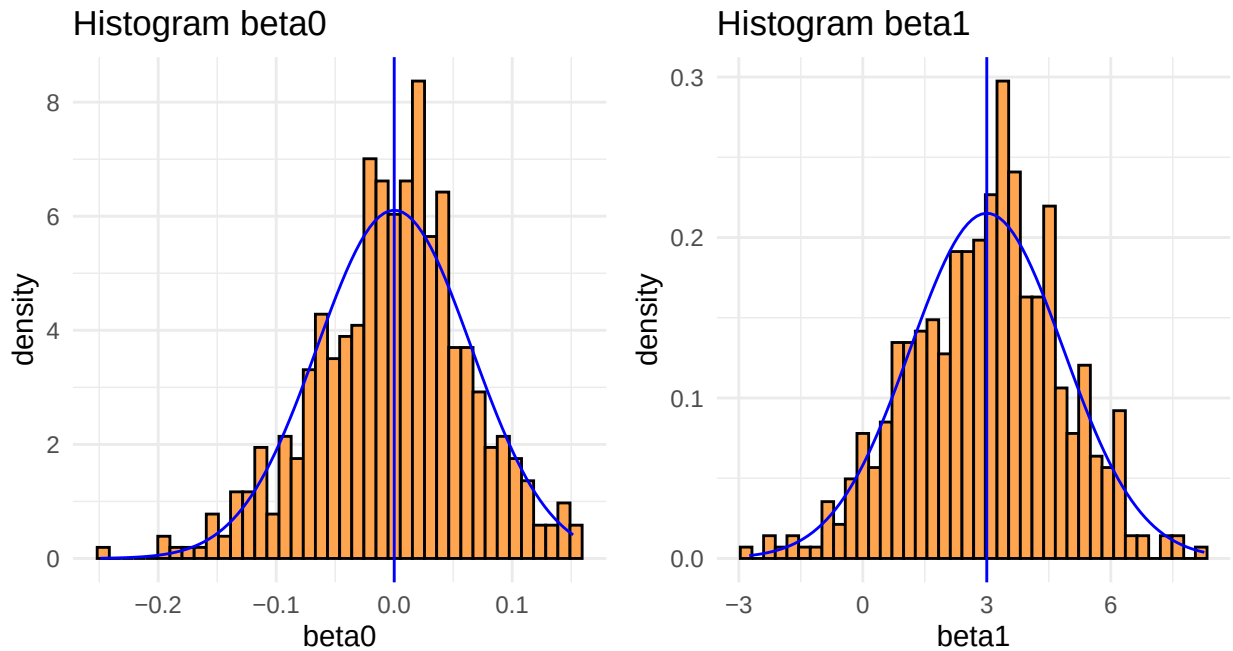

Możemy zobaczyć, że wśród prawdziwych wartości tym razem dużo częściej otrzymywaliśmy bardzo zbliżone wartości do poprzednich, w porównaniu do poprzedniego wykresu. Wciąż jesteśmy jednak w stanie zobaczyć, że kształt histogramu jest bardzo zbliżony do krzywej przedstawiającej asymptotyczną gęstość. Ponownie możemy zobaczyć, że wartości dla $\hat{\beta}_0$ są dużo bliżej siebie (również w stosunku do wartości otrzymywanych w poprzednim zadaniu). Z kolei dla $\hat{\beta}_1$ nie można zobaczyć znaczącej poprawy w tej kwestii.

Przyjrzyjmy się teraz wartościom obciążenia estymatora wektora β oraz przeanalizujmy jego normę supremum.

Table 5: Wartości obciążenia dla beta

beta0_bias	beta1_bias	beta2_bias	beta3_bias
-0.0016	-0.0195	0.0397	0.0679

Jak widać w powyższej tabeli, wartości obciążenia są porównywalne lub w niektórych przypadkach znacząco lepsze niż w poprzednim przypadku. Widzimy zatem poprawę wśród wartości estymatorów. Norma supremum z kolei wynosi 9.4943, co z kolei jest dość dużą wartością, ale bardzo zbliżoną do tej otrzymanej w poprzednim przypadku.

4.2 Estymator $\hat{\Sigma}$

Ponownie przyjrzyjmy się teraz wartościom estymowanym dla parametrów związanych z macierzą Σ - $\hat{\rho}$ oraz $\hat{\gamma}$.

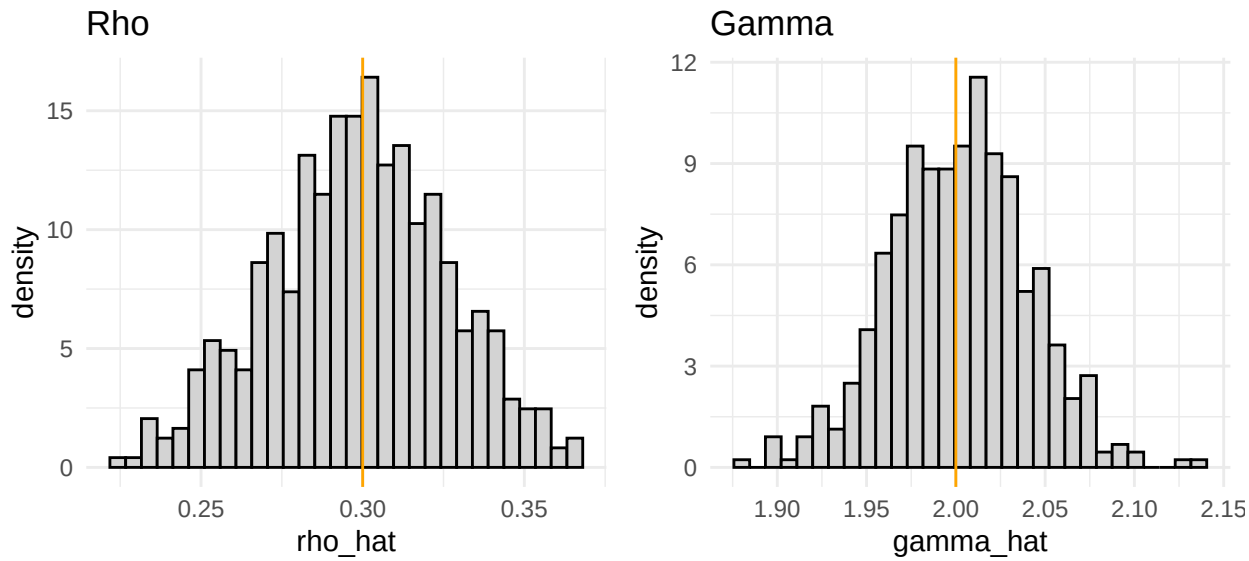

Na tych wykresach z kolei, możemy zobaczyć zbliżenie się ich kształtu do krzywej Gaussa, jak również zmniejszenie się rozrzutu między zmiennymi. Poprzednio mogliśmy zobaczyć, że wartości dla $\hat{\rho}$ znajdują się między -0.25, a 0.75, natomiast teraz są one między około 0.23, a 0.37. Jest to znacząco pozytywna zmiana. Podobną tendencję możemy zobaczyć dla zmiennej $\hat{\gamma}$. Obciążenie tych wartości wynosi -0.0013 dla $\hat{\rho}$ oraz 0.0019 dla $\hat{\gamma}$. Ponownie jest ono mniejsze niż w poprzednim przypadku.

5 Zadanie 4.

Tym razem zajmiemy się podobną analizą, gdy zmienimy liczbę pomiarów dla poszczególnych obiektów z $k = 3$ na $k = 30$.

5.1 Estymator $\hat{\beta}$

Ponownie przyjrzyjmy się histogramom dla estymatorów pierwszych dwóch współrzędnych w wektorze wartości β.

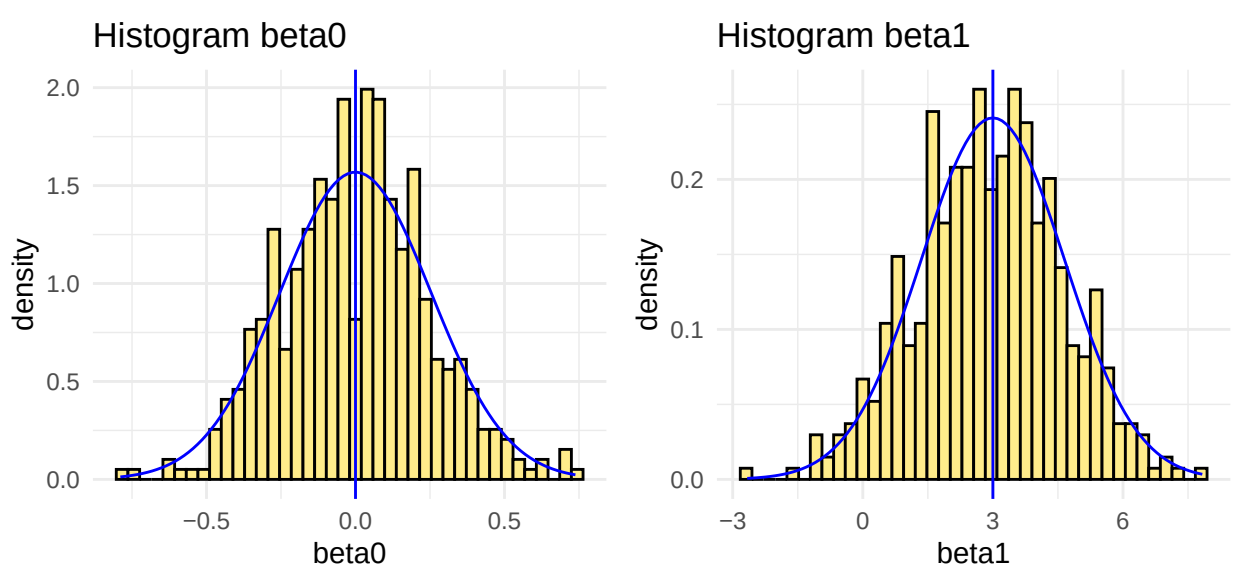

Jak widać powyższe histogramy są ponownie bardzo zbliżone do teoretycznej krzywej rozkładu. Wartości ponownie są bardziej zbliżone do krzywej. Tym razem $\hat{\beta}_0$ przyjmuje wartości dla wartości podobnych jak w pierwszym z przypadków.

Spójrzmy teraz na wartości obciążenia dla wektora β oraz wartość normy supremum, które umieszczę poniżej.

Table 6: Wartości obciążenia dla beta

beta0_bias	beta1_bias	beta2_bias	beta3_bias
-0.002	-0.0874	0.0038	0.0395

Ponownie obciążenie jest bardzo małe, porównywalne do poprzednich przypadków. Z kolei norma supremum dla tego przypadku wynosi 7.8294, które jest najmniejszą wartością ze wszystkich.

5.2 Estymator $\hat{\Sigma}$

Spójrzmy teraz na kolejne histogramy z wartościami estymatorów $\hat{\rho}$ oraz $\hat{\gamma}$.

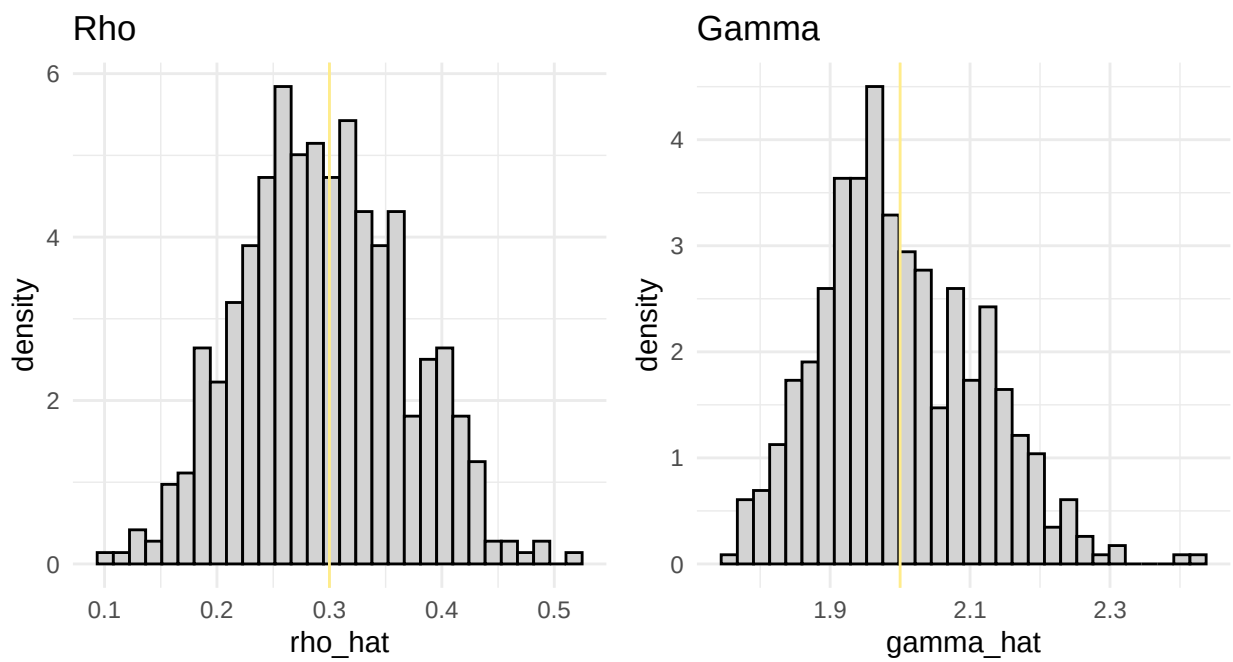

Ponownie widać, że histogram ma kształt podobny do krzywej Gaussa. Estymatory tym razem znajdują się między wartościami około 0.1 i 0.5 dla $\hat{\rho}$ oraz między 1.7509 i 2.4209 . Widać, że dla ρ przedział wartości estymatorów jest mniejszy niż w pierwszym z przypadków, jednak większy niż w drugim. Z kolei dla γ wydaje się być porównywalny do pierwszego z przypadków i większy od drugiego z nich. Jeśli chodzi o obciążenie to możemy zobaczyć, że wynosi ono tutaj -0.005 dla $\hat{\rho}$ oraz -2×10^{-4} dla $\hat{\gamma}$. W tym przypadku zatem jest ono najmniejsze ze wszystkich.

6 Zadanie 5.

Przedostatnim przypadkiem, który będziemy rozpatrywać będzie przeanalizowanie, jak na wyniki wpływa zmiana liczby kolumn macierzy planu z $p = 4$ na $p = 40$. Zauważmy, że w takim wypadku otrzymamy więcej elementów w wektorze β. Z tego względu zakładam, że wektor β należy uzupełnić wartościami 0 po ostatniej podanej wartości.

6.1 Estymator $\hat{\beta}$

Przyjrzyjmy się zatem, jak prezentuje się histogram wartości dla $\hat{\beta}_0$ oraz $\hat{\beta}_1$.

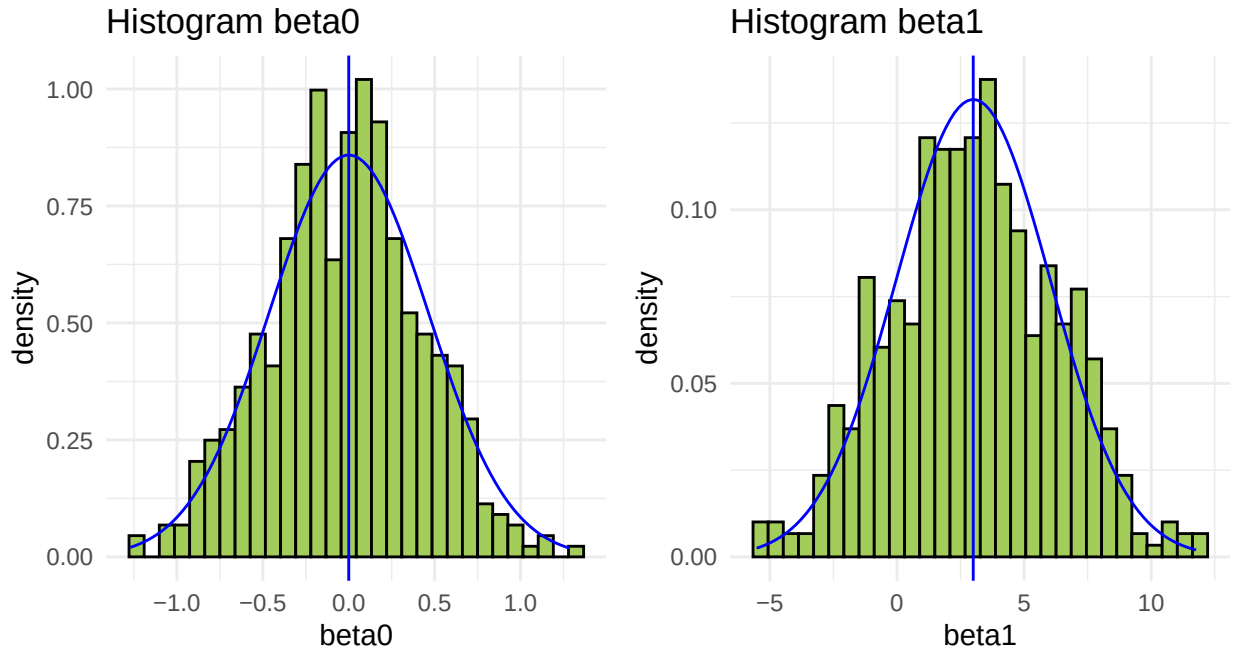

Wykresy w tych przypadkach są bardzo podobne do tych, które widzieliśmy w pierwszym przypadku. Dla interceptu wartości estymatorów są bardzo zbliżone, jednak dla β_1 estymatory mają nieco większe wielkości (w pierwszym przypadku było to między -2.1213, a 10.8726, z kolei tym razem jest to między -5.5191, a 11.7687. Krzywe z asymprotycznym rozkładem również są bardzo bliskie wartościom na histogramie.

Spójrzmy teraz na obciążenie dla $\hat{\beta}$. Tabelę tym razem wykonam w pionie, aby wszystkie wartości dobrze się zmieściły.

Table 7: Wartości obciążenia dla beta

beta0_bias	beta1_bias	beta2_bias	beta3_bias	beta4_bias	beta5_bias	beta6_bias	beta7_bias
-0.0214	0.003	0.1399	0.0107	0.2725	0.0114	-0.2161	-0.1097

beta8_bias	beta9_bias	beta10_bias	beta11_bias	beta12_bias	beta13_bias	beta14_bias	beta15_bias
0.1357	0.0796	0.1422	-0.3084	-0.1127	0.0973	0.0568	0.0594

beta16_bias	beta17_bias	beta18_bias	beta19_bias	beta20_bias	beta21_bias	beta22_bias	beta23_bias
0.0739	-0.1891	0.1324	-0.0669	0.0411	-0.0269	-0.1389	0.029

beta24_bias	beta25_bias	beta26_bias	beta27_bias	beta28_bias	beta29_bias	beta30_bias	beta31_bias
-0.2764	0.1695	-0.058	-0.0093	0.0282	0.0322	-0.0867	-0.0813

beta32_bias	beta33_bias	beta34_bias	beta35_bias	beta36_bias	beta37_bias	beta38_bias	beta39_bias
-0.0874	-0.0381	0.1018	-0.0908	-0.2132	0.2606	-0.0056	-0.0813

Jak widać powyżej, wartości obciążenia są większe niż w poprzednich przypadkach. tym razem wartości osiągają nawet około 0.3. Wynika to najpewniej z tego, że mając dużo prawdziwych wartości 0, możemy

widzieć błędne przypisywanie istotności zmiennym nieistotnym. Z kolei norma supremum estymatora $\hat{\beta}$ w tym przypadku wynosi aż 19.0441, co jest zgodne z powyższą tezą.

6.2 Estymator $\hat{\Sigma}$

Spójrzmy teraz na histogramy z wartościami $hat\rho$ oraz $\hat{\gamma}$

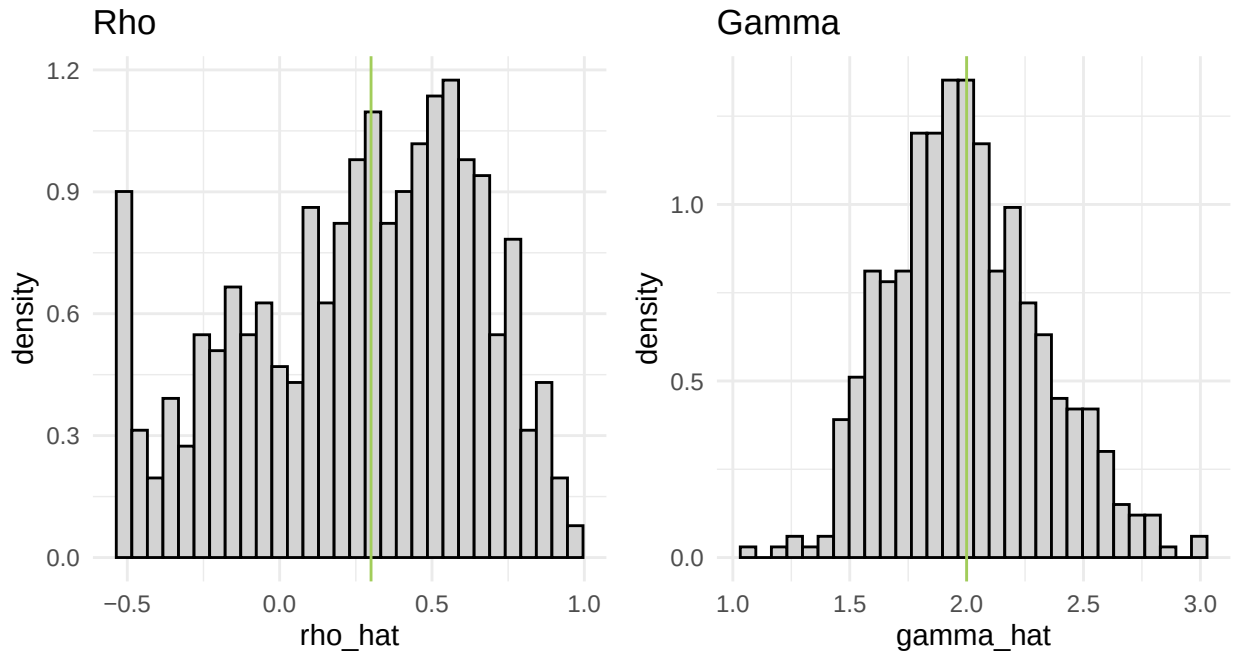

Na histogramach, tym razem, nie możemy zobaczyć krzywej gaussa, jeśli chodzi o estymator $\hat{\rho}$ w tym przypadku nie jest widoczna żadna struktura. W szczególności dane są dość mocno oddalone od prawdziwych. W przypadku $\hat{\gamma}$ jest temu histogramowi znacznie bliżej do krzywej rozkładu normalnego, ale również nie jest to idealny rozkład. Dane również są dość oddalone od prawdziwej wartości. Z kolei patrząc na obciążenia, dla $\hat{\rho}$ wynosi ono -0.0395, natomiast dla $\hat{\gamma}$ jest to 6×10^{-4}. Jest ono ponownie bardzo małe, dla $\hat{\gamma}$ jest wręcz jednym z najmniejszych wyników.

7 Zadanie 6.

Na koniec sprawdźmy jak na wyniki wpływa zmiana metody konstrukcji macierzy na metodę największej wiarogodności w porównaniu do poprzedniej metody REML.

7.1 Estymator $\hat{\beta}$

W pierwszej kolejności przyjrzyjmy się, ponownie, histogramom dla dwóch pierwszych współrzędnych estymatora $\hat{\beta}$.

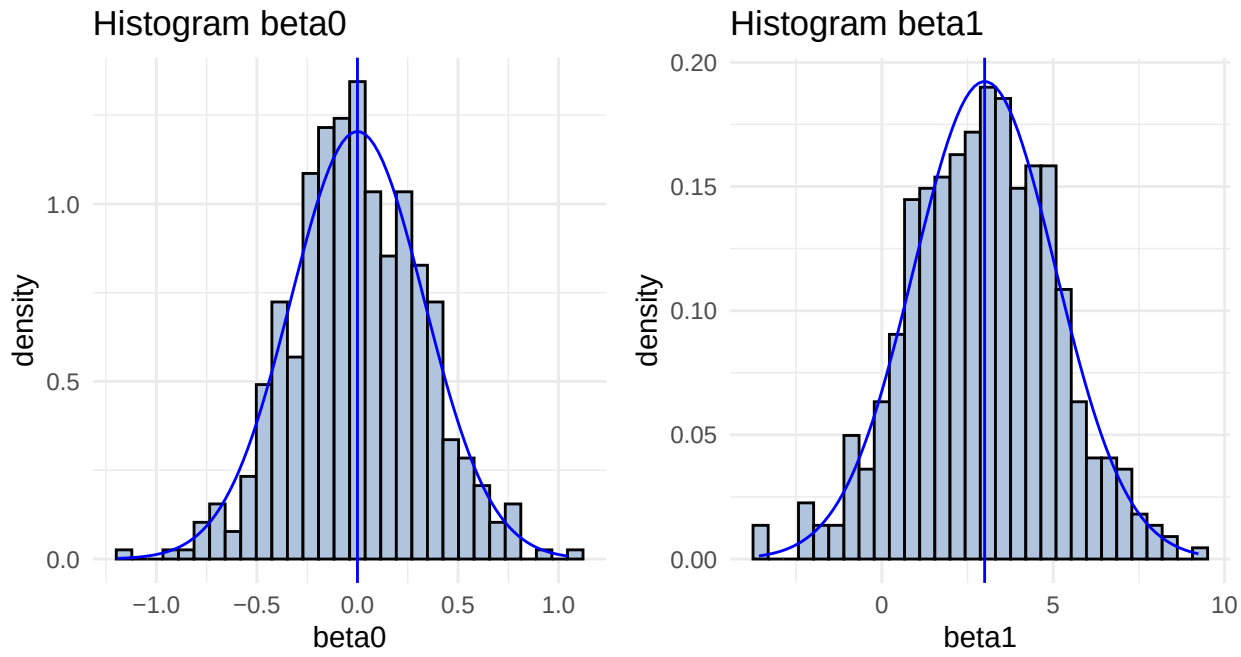

Jak widać, histogramy są bardzo bliskie teoretycznym wartościom asymptotycznego rozkładu tych estymatorów. Wyniki w tym przypadku są bardzo podobne do pierwszego z przypadków.

Przyjrzyjmy się teraz tabeli z obciążeniami oraz normie supremum estymatora wektora β.

Table 8: Wartości obciążenia dla beta

beta0_bias	beta1_bias	beta2_bias	beta3_bias
0.0023	-0.0647	0.0328	-0.0208

Patrząc na powyższą tabelę można zobacztć, że tym razem wartości są porównywalne do tych z pierwszego przypadku. Nie można zobaczyć znaczącej zmiany. Norma supremum dla $\hat{\beta}$ wynosi 9.2362 i ponownie jest dość podobna do poprzednio otrzymywanych.

7.2 Estymator $\hat{\Sigma}$

Przyjrzyjmy się na koniec histogramom dla $\hat{\rho}$ oraz $\hat{\gamma}$.

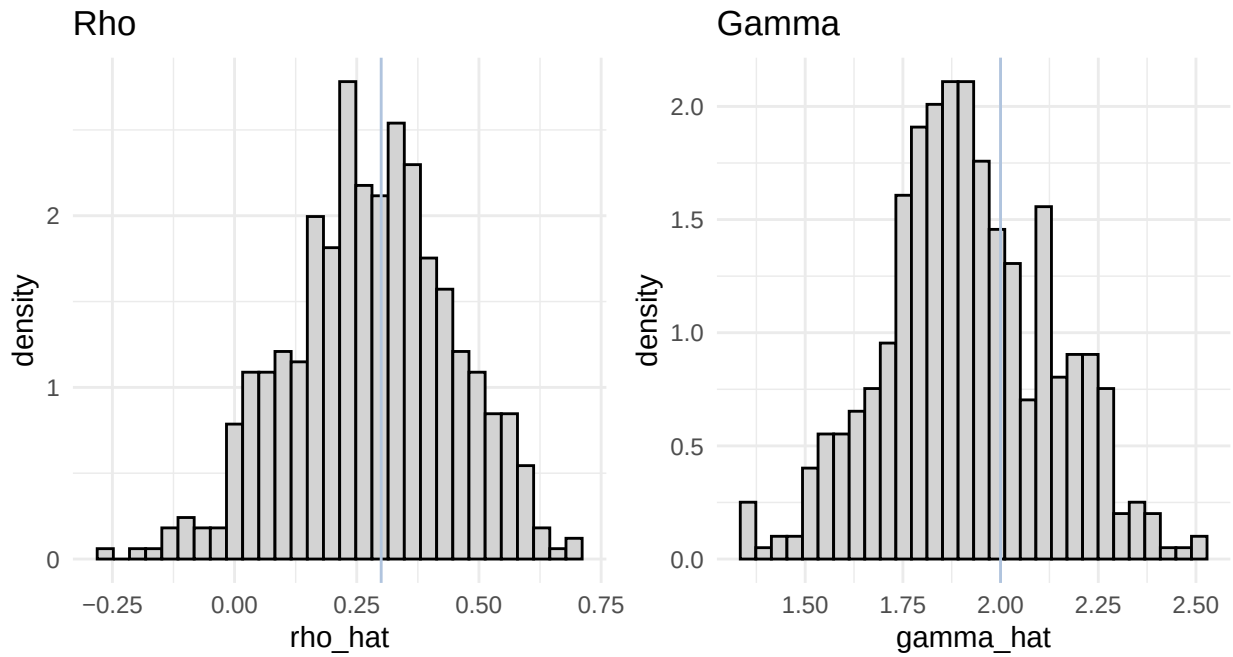

Ponownie nie możemy powiedzieć, że widoczne na histogramach wartości w znaczący sposób różnią się od poprzednich.

8 Podsumowanie

Z powyższych rozważań możemy zauważyć, że empiryczne działania są zgodne z teorią. Przede wszystkim można zobaczyć, że rozkłady estymatora $\hat{\beta}$ są bardzo zbliżone do gęstości swojego asymptotycznego rozkładu. Dodatkowo, mogliśmy zobaczyć, że w większości przypadków (poza większą liczbą regresorów) mamy histogramy dla $\hat{\rho}$ oraz $\hat{\gamma}$ bardzo zbliżone do gęstości rozkładu normalnego.

Zastanówmy się jednak jak poszczególne parametry również wpływają na wartości estymatorów. Pierwszym co spostrzegliśmy było to, że dla większej liczby obiektów, estymatory β, jak i ρ i γ są bliżej siebie (i tym samym prawdziwej wartości), jak również maleje norma supremum estymatora $\hat{\beta}$. Dla zwiększonej liczby pomiarów dla poszczególnych obiektów mogliśmy zaobserwować najniższą ze wszystkich wartość normy supremum. Obciążenie również było jednym z najniższych, zarówno dla β jak i ρ czy γ. Zwiększenie liczby nieistotnych regresorów wpływa na pogorszenie się estymatorów β (w tym dość duże obciążenie i norma supremum), a także utratę normalności w przypadku parametru $\hat{\rho}$. Z kolei zmiana metody z REML na ML nie wskazuje na żadne znaczące różnice